

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
Khoa Công nghệ Thông tin

BÁO CÁO ĐỒ ÁN 3
CÁC CHỦ ĐỀ MỚI TRONG NGHIÊN CỨU HỌC MÁY

Generative AI Meets Reinforcement Learning

ICML 2025 Tutorial – Benjamin Eysenbach & Amy Zhang

Môn học: Nhập môn Học Máy

Mã môn: CSC14005

Học kỳ: Học kỳ 2 – 2025/2026

Giảng viên: ThS. Lê Nhật Nam

MSSV	Họ và tên	Phần đóng góp
23120059	Trần Đình Luân	Tổng quan, kiến thức nền
23120063	Nguyễn Thành Nguyên	Nội dung chính – Phần 1
23120062	Trần Kim Ngọc	Nội dung chính – Phần 2
23120084	Nguyễn Mạnh Thắng	Demo thực nghiệm
23120064	Nguyễn Thiện Nhân	Đánh giá, kết luận

Mục lục

1	Tổng quan chủ đề	1
1.1	Giới thiệu bài toán	1
1.2	Động lực nghiên cứu	1
1.2.1	Giới hạn của Học Bất chước	1
1.2.2	Giới hạn của Thiết kế Hàm Thưởng	2
1.2.3	Sự hội tụ của hai lĩnh vực	2
1.3	Tầm quan trọng và tính thời sự	2
1.3.1	Ứng dụng thực tiễn	2
1.3.2	Tổng quát hóa – bài toán còn bỏ ngỏ	3
1.4	Cấu trúc báo cáo	3
2	Kiến thức nền	4
2.1	Học Tăng cường	4
2.1.1	Vòng lặp Tác nhân–Môi trường: Bức tranh tổng thể	4
2.1.2	Định nghĩa bài toán Học Tăng cường: Quá trình Quyết định Markov	5
2.1.3	Chính sách và Mục tiêu Học Tăng cường	5
2.1.4	So sánh Học Tăng cường và Học Có Giám sát	6
2.1.5	Hàm Giá trị và Phương trình Bellman	7
2.1.6	Gradient Chính sách	7
2.2	Mô hình Tạo sinh	8
2.2.1	Tổng quan và Phân loại	8
2.2.2	Bộ Mã hóa Biến phân (VAE)	8
2.2.3	Mạng Đối kháng Tạo sinh (GAN)	9
2.2.4	Mô hình Khuếch tán	9
2.2.5	Mô hình Khớp Luồng	10
2.2.6	Transformer và Mô hình Tự Hồi quy	11
2.3	Thước đo Kế tiếp	12

2.3.1	Ý nghĩa trực quan và ví dụ minh họa	12
2.3.2	Liên hệ với Hàm Q	12
2.3.3	Tính toán qua Bellman	13
2.3.4	Vị trí trong Tutorial	13
2.4	Bảng đối chiếu Học Tăng cường và Mô hình Tạo sinh	13
3	Nội dung chính của bài hướng dẫn	15
3.1	Mô hình tạo sinh trong hệ thống học tăng cường	15
3.1.1	So sánh mục tiêu học có giám sát và mục tiêu RL	15
3.1.2	Mô hình tạo sinh làm mô hình thế giới	17
3.1.3	Học có trọng số phần thưởng và hàm điểm số	18
3.1.4	Mô hình tạo sinh làm chính sách	21
3.1.5	Nghiên cứu trường hợp: Diffusion-DICE	22
3.1.6	DDPO: xem quá trình khử nhiễu như một MDP	24
3.2	Quá trình tương tác như một mô hình tạo sinh	25
3.2.1	Cách chính sách và environment sinh dữ liệu	25
3.2.2	Đạt đích và thước đo chiếm dụng	26
3.2.3	Goal-conditioned sao chép hành vi	28
3.2.4	Học tăng cường song nguyên và DICE	29
3.2.5	f -Policy Gradients và state-MaxEnt RL	30
3.2.6	Offline học tăng cường có điều kiện đích	31
3.3	Học Likelihoods	34
3.3.1	Successor Measure	34
3.3.2	Ước lượng Mật độ Trực tiếp	34
3.3.3	Học Tương phản Thời gian	35
3.3.4	Học Tăng cường Tổng quát từ Tỷ lệ Mật độ	37
3.3.5	Thước đo Kế tiếp Nguyên mẫu (PSM)	39
3.3.6	RLZero: Học Tăng cường Không cần Huấn luyện lại từ Ngôn ngữ Tự nhiên	40
3.4	Data Tự Sinh	43

3.4.1	Bài toán Khám phá	43
3.4.2	Trao quyền	43
3.4.3	Học Kỹ năng	44
	Phân tích Hạn chế và Đề xuất Cải tiến	47
4	Thực nghiệm và Kết quả	49
4.1	Thiết lập Bài toán	49
4.2	Các Phương pháp So sánh	49
4.3	Kết quả Thực nghiệm	51
4.4	Mở rộng 1: Thực nghiệm trên Tập dữ liệu 4 Cụm (4-Cluster)	52
4.5	Mở rộng 2: Khảo sát Siêu tham số Hệ số Dẫn đường	53
4.6	Mô tả Demo	54
5	Đánh giá và Kết luận	55
5.1	Đánh giá tổng thể tutorial	55
5.1.1	Đóng góp Khoa học Chính	55
5.1.2	Tính nhất quán và mạch lạc của Khung nghiên cứu	55
5.2	Ưu điểm của Hướng tiếp cận	56
5.2.1	Loại bỏ sự phụ thuộc vào Thiết kế Hàm Thưởng	56
5.2.2	Mở rộng Năng lực Biểu diễn của Chính sách	56
5.2.3	Khả năng Học Không Giám sát và Dữ liệu Tự thu thập	56
5.3	Hạn chế và Thách thức Còn tồn tại	57
5.3.1	Hạn chế về Khả năng Mở rộng	57
5.3.2	Vấn đề Dịch chuyển Phân phối	57
5.3.3	Phụ thuộc vào Chất lượng Mô hình Phần thưởng	57
5.3.4	Thách thức trong Tổng quát hóa	58
5.4	Hướng Nghiên cứu Tương lai	58
5.4.1	Tích hợp Mô hình Nền tảng với Học Tăng cường	58
5.4.2	Cải thiện Hiệu quả Mẫu trong Môi trường Thực	58
5.4.3	Học Tăng cường Không cần Phần thưởng ở Quy mô Lớn	58

5.4.4	Lý thuyết về Tổng quát hóa trong Học Tăng cường	59
5.5	Nhận xét về Ý nghĩa Thực tiễn	59
5.6	Kết luận	59

Danh mục bảng biểu

1	Bảng thuật ngữ Anh–Việt.	vii
2	Ba hướng giao thoa giữa AI Tạo sinh và Học Tăng cường.	2
3	Các thành phần của Quá trình Quyết định Markov, minh họa qua game Tetris.	5
4	Các khái niệm tương đương giữa Học Tăng cường và Mô hình Tạo sinh.	14
5	Các công trình chính trong Phần I và Phần II được nhóm theo vai trò kỹ thuật trong mạch lập luận.	15
6	So sánh các phương pháp ước lượng thước đo kế tiếp.	36
7	Win rate của các phương pháp khi đánh giá bằng GPT-4o-preview trên 25 tasks trong DeepMind Control Suite.	41
8	Tóm tắt các phương pháp chính và vị trí trong framework	60

Danh mục hình ảnh

1	Vòng lặp tác nhân–môi trường trong Học Tăng cường. Tác nhân gửi hành động cho môi trường; môi trường phản hồi trạng thái mới và phần thưởng. Mục tiêu tác nhân là học chính sách π tối đa hóa tổng phần thưởng tích lũy.	4
2	Pipeline model-based RL với mô hình thế giới: generative model được huấn luyện để học dynamics từ transition data, sau đó hỗ trợ học chính sách. Nguồn hình: Figure 3 trong [7].	18
3	Diễn giải RL như một bài toán latent-variable. Các path dẫn đến high-reward state đóng vai trò latent variables cần được suy luận. Nguồn hình: Figure 6 trong [7].	19
4	Sơ đồ cho thấy vai trò của hàm điểm số: cùng đại lượng $\nabla_{\theta} \log \pi_{\theta}$ xuất hiện trong gradient chính sách và trong generative model, nên chính sách tạo sinh có thể được cập nhật bằng tín hiệu RL.	20

5	Luồng guide-then-select trong Diffusion-DICE: Guide tạo candidate actions bằng behavior score và density-ratio signal, còn Select chỉ dùng hàm Q sau khi candidate đã được giữ gần support dữ liệu.	23
6	Toy case 2D bandit của Diffusion-DICE: action trong bộ dữ liệu nằm trong vùng hình khuyên; true reward cao ở outer circle; learned reward overestimate inner circle; Diffusion-DICE giảm khai thác lỗi tốt hơn các hướng guide-only hoặc select-only. Nguồn hình: Figure 7 trong [7].	23
7	So sánh generative models chuẩn với tương tác trong RL. Cả hai đều dùng nhiều bước tính toán hoặc tương tác để tạo mẫu. Nguồn hình: Figure 8 trong [7].	26
8	Quá trình tương tác tạo sinh: mỗi bước chính sách sinh action, environment sinh state kế tiếp, và toàn bộ vòng lặp tạo ra mẫu tương lai s_f	26
9	Đạt đích thay nhiều thành phần reward thủ công bằng một desired observation g ; mục tiêu kỹ thuật là tăng xác suất $p^\pi(s_f = g)$	27
10	Tổng hợp hai mức phân tích của tutorial. Phần I đặt generative models vào hệ RL. Phần II xem quá trình tương tác của agent như một mô hình tạo sinh tạo ra occupancy, goal và outcome distribution.	33
11	Thước đo kế tiếp (thước đo chiếm dụng trạng thái chiết khấu) là phân phối các trạng thái tương lai mà agent có thể đến được. Phần III giới thiệu các kỹ thuật ước lượng phân phối này và sử dụng nó cho RL. Nguồn: [7].	34
12	Ước lượng relative likelihood qua temporal contrastive learning. Classifier học phân biệt cặp (s, a, s_f) thật (future state thực sự) với cặp ngẫu nhiên, từ đó ước lượng tỉ lệ xác suất $p^\pi(s_f s, a)/p(s_f)$. Nguồn: [7].	36
13	Framework của RLZero gồm 3 bước: Imagine (tưởng tượng video từ ngôn ngữ), Project (chiếu về không gian quan sát của agent), Imitate (suy ra chính sách zero-shot). Nguồn: [19].	40
14	Trao quyền được đo bằng thông tin tương hỗ giữa hành động và trạng thái tương lai. Vị trí ngã tư có trao quyền cao (nhiều phương án tác động đến tương lai) so với ngã cụt (trao quyền thấp). Nguồn: [7].	44
15	Minh họa Skill Learning (DIAYN): agent học các skill đa dạng (chạy, nhảy, cân bằng) bằng cách tối đa hóa thông tin tương hỗ giữa skill label z và quỹ đạo τ . Discriminator $q(z s)$ học nhận biết skill từ trạng thái, tạo ra intrinsic reward cho chính sách. Nguồn: [7].	46

16	Kết quả trực quan hóa bài toán 2D Bandit Toy Case trên Annular Dataset. Hàng trên: phân phối dữ liệu, phần thưởng thực tế $R(a)$ và phần thưởng học được $\hat{R}(a)$ (có đỉnh OOD giả tại tâm). Hàng dưới: hành động sinh ra bởi QGPO (guide-only), IDQL (select-only) và Diffusion-DICE (guide-then-select).	51
17	Kết quả trực quan hóa trên tập dữ liệu 4 cụm Gaussian rời rạc (4-Cluster Dataset). Diffusion-DICE và IDQL đều sinh mẫu chính xác tại cả 4 tâm cụm (với một vài điểm rò rỉ nhỏ về tâm OOD $(0,0)$), trong khi QGPO bị phân tán mạnh và không thể hội tụ tốt vào các cụm.	52
18	Kết quả khảo sát Guidance Scale cho QGPO và Diffusion-DICE. Trái: Tỷ lệ hành động an toàn (ID Ratio). Phải: Phần thưởng thực tế trung bình (True Reward).	53

Bảng Thuật ngữ

Bảng dưới đây tổng hợp các thuật ngữ chuyên ngành tiếng Anh được sử dụng trong báo cáo kèm theo giải thích bằng tiếng Việt.

Bảng 1: Bảng thuật ngữ Anh–Việt.

Thuật ngữ tiếng Anh	Dịch tiếng Việt	Ghi chú
Reinforcement Learning (RL)	Học Tăng cường	Nhánh học máy học qua tương tác
Generative AI / Generative Model	AI Tạo sinh / Mô hình Tạo sinh	Mô hình có thể sinh mẫu mới
Imitation Learning	Học Bắt chước	Học từ dữ liệu hành vi chuyên gia
Reward Engineering	Thiết kế Hàm Thưởng	Xây dựng tín hiệu phần thưởng cho RL
Reward Hacking	Khai thác Phần thưởng	Tối ưu proxy thay vì mục tiêu thật
Policy	Chính sách	Quy tắc ra quyết định của tác nhân
Policy Gradient	Gradient Chính sách	Phương pháp tối ưu chính sách
Score Function	Hàm Điểm số	Gradient của log-xác suất
Trajectory	Quỹ đạo	Chuỗi trạng thái–hành động–thưởng
Return / Discounted Return	Lợi tức / Lợi tức Chiết khấu	Tổng phần thưởng (có chiết khấu)
Value Function / Q-function	Hàm Giá trị / Hàm Q	Ước lượng lợi tức kỳ vọng
Bellman Equation	Phương trình Bellman	Quan hệ đệ quy của hàm giá trị
Markov Decision Process (MDP)	Quá trình Quyết định Markov	Khung hình thức hóa bài toán RL
Successor Measure	Thước đo Kế tiếp	Phân phối trạng thái tương lai
Occupancy Measure	Thước đo Chiếm dụng	Phân phối trạng thái–hành động

Bảng 1 – Tiếp theo từ trang trước

Thuật ngữ tiếng Anh	Dịch tiếng Việt	Ghi chú
Diffusion Model	Mô hình Khuếch tán	Mô hình tạo sinh qua khử nhiễu
Flow Matching	Khớp Luồng	Mô hình tạo sinh qua trường vector
Transformer	Transformer	Kiến trúc dựa trên cơ chế tự chú ý
Self-Attention	Tự chú ý	Cơ chế tập trung giữa các token
Autoregressive Model	Mô hình Tự Hồi quy	Sinh token tuần tự từng bước
VAE (Variational Autoencoder)	Bộ Mã hóa Biến phân	Mô hình tạo sinh có không gian tiềm ẩn
GAN (Generative Adversarial Network)	Mạng Đối kháng Tạo sinh	Mô hình tạo sinh kiểu bộ tạo-bộ phân biệt
World Model	Mô hình Thế giới	Mô hình học hàm chuyển trạng thái
Model-Based RL	Học Tăng cường Dựa trên Mô hình	RL sử dụng mô hình thế giới
Offline RL	Học Tăng cường Ngoại tuyến	RL học từ tập dữ liệu cố định
Goal-Reaching	Đạt Đích	Bài toán đưa tác nhân đến trạng thái đích
Goal-Conditioned RL	Học Tăng cường Có Điều kiện Đích	RL với chính sách phụ thuộc mục tiêu
Behavioral Cloning (BC)	Sao chép Hành vi	Học trực tiếp phân phối hành động
GCBC	Sao chép Hành vi Có Điều kiện Đích	BC mở rộng với điều kiện mục tiêu
Dual RL	Học Tăng cường Song nguyên	RL qua bài toán đối ngẫu nguyên
DICE	DICE	Phương pháp khớp phân phối chiếm dụng
Distribution Matching	Khớp Phân phối	Đưa phân phối chính sách về đích
Density Ratio	Tỉ lệ Mật độ	Tỉ lệ giữa hai phân phối xác suất

Bảng 1 – Tiếp theo từ trang trước

Thuật ngữ tiếng Anh		Dịch tiếng Việt	Ghi chú
Temporal Learning	Contrastive	Học Tương phản Thời gian	Học phân biệt cặp thật/giả theo thời gian
Forward-Backward Representation		Biểu diễn Tiến-Lùi	Biểu diễn nhân tố hóa thước đo kế tiếp
Zero-shot RL		Học Tăng cường Không cần Huấn luyện lại	Suy ra chính sách không cần train thêm
Skill Learning		Học Kỹ năng	Học các hành vi có thể tái sử dụng
Empowerment		Trao quyền	Khả năng tác nhân tác động đến tương lai
Mutual Information		Thông tin Tương hỗ	Đo lường phụ thuộc giữa hai biến
Behavioral Model (BFM)	Foundation	Mô hình Nền tảng Hành vi	Mô hình nền tảng cho không gian hành vi
Self-Supervised RL		Học Tăng cường Tự Giám sát	RL tự tạo phần thưởng nội tại
RLHF		Học Tăng cường từ Phản hồi Con người	Fine-tune mô hình theo ý muốn người dùng
Error Exploitation		Khai thác Lỗi	Chính sách khai thác sai số của critic
Out-of-Distribution (OOD)		Ngoài Phân phối	Dữ liệu nằm ngoài vùng huấn luyện
Denoising		Khử nhiễu	Quá trình loại bỏ nhiễu dần dần
Score-Based Diffusion		Khuếch tán Dựa trên Điểm số	Khuếch tán dùng hàm điểm số
In-Distribution		Trong Phân phối	Dữ liệu nằm trong vùng huấn luyện
Horizon Generalization		Tổng quát hóa Chân trời	Huấn luyện ngắn, suy ra horizon dài
Cross-Embodiment Transfer		Chuyển giao Xuyên Thể xác	Chuyển kỹ năng sang robot có hình dạng khác

1. Tổng quan chủ đề

1.1. Giới thiệu bài toán

Năm 1770, Wolfgang von Kempelen giới thiệu với châu Âu một cỗ máy biết chơi cờ mang tên “Mechanical Turk”. Đây là một thiết bị tinh vi với hàng chục bánh răng và đòn bẩy. Nó đánh bại Napoleon, Benjamin Franklin và vô số đối thủ khác. Hóa ra, toàn bộ cỗ máy chỉ là vỏ bọc, bên trong có một kỳ thủ thật ngồi điều khiển mọi nước đi qua hệ thống gương phản chiếu.

Câu chuyện này phản ánh chính xác trạng thái của AI ngày nay. Phần lớn các hệ thống AI hiện đại, từ GPT-4, Gemini cho đến Stable Diffusion đều được xây dựng trên nguyên tắc **maximum likelihood imitation**: mô hình học cách tái tạo hành vi của con người bằng cách tối đa hóa xác suất sinh ra dữ liệu giống dữ liệu huấn luyện. Phương pháp này rất mạnh, nhưng chứa đựng một giới hạn nền tảng không thể tránh khỏi:

$$\text{Khả năng của mô hình} \leq \text{Khả năng của dữ liệu huấn luyện} \quad (1)$$

Nếu tất cả dữ liệu đều sai, mô hình sẽ sai theo. Nếu chưa có con người nào giải được một bài toán, mô hình không thể học cách giải nó từ dữ liệu đó. Đây là bài toán cốt lõi mà tutorial *Generative AI Meets Reinforcement Learning* [7] đặt ra: làm thế nào để xây dựng AI có thể **vượt qua giới hạn của dữ liệu huấn luyện**?

Tutorial được trình bày tại ICML 2025 bởi Benjamin Eysenbach (Princeton University) và Amy Zhang (UT Austin), xoay quanh hai câu hỏi liên quan chặt chẽ:

- Học Tăng cường và AI Tạo sinh: hai lĩnh vực tưởng như tách biệt này liệu có chia sẻ cùng cấu trúc toán học không?
- Nếu có, chúng ta có thể khai thác điều đó để xây dựng các hệ thống AI mạnh mẽ hơn như thế nào?

1.2. Động lực nghiên cứu

1.2.1. Giới hạn của Học Bất chước

Như đã trình bày, phần lớn AI hiện đại được huấn luyện bằng cách tối đa hóa khả năng tái tạo hành vi của con người. Cách tiếp cận này hiệu quả khi có đủ dữ liệu chất lượng cao và nhiệm vụ nằm trong phân phối dữ liệu. Tuy nhiên, nó gặp khó khăn

cơ bản khi bài toán đòi hỏi sự sáng tạo vượt ngoài dữ liệu, hoặc khi chưa có ai giải được bài toán đó trước đây.

Một hệ quả đáng lo ngại hơn nữa là hiện tượng *sup đố mô hình*: khi AI được huấn luyện đệ quy trên dữ liệu do chính AI sinh ra, chất lượng suy giảm theo cấp số nhân [18].

1.2.2. Giới hạn của Thiết kế Hàm Thưởng

Nền tảng của Học Tăng cường là tín hiệu phần thưởng (reward). Tuy nhiên, hầu hết bài toán thực tế rất khó thiết kế hàm thưởng phù hợp. Đây là mâu thuẫn cốt lõi: Học Tăng cường hứa hẹn tìm ra giải pháp tốt hơn con người, nhưng chính hàm thưởng lại đòi hỏi con người phải hiểu rõ vấn đề mới có thể thiết kế được.

Với bài toán dọn phòng robot, người thiết kế phải tự hỏi: nhặt một chiếc áo được bao nhiêu điểm? Xếp sách ngay ngắn được bao nhiêu? Nếu thiết kế sai, robot có thể học cách “gian lận” thay vì thực sự dọn dẹp. Đây là một hiện tượng được gọi là *khai thác phần thưởng*.

1.2.3. Sự hội tụ của hai lĩnh vực

Trong nhiều thập kỷ, Học Tăng cường và AI Tạo sinh phát triển song song nhưng tương đối độc lập. Gần đây, giới nghiên cứu nhận ra rằng hai lĩnh vực này đang giải quyết cùng một bài toán từ hai góc nhìn khác nhau, và khai thác điểm chung này mở ra ba hướng giao thoa chính:

Bảng 2: Ba hướng giao thoa giữa AI Tạo sinh và Học Tăng cường.

Hướng	Ý nghĩa
AI Tạo sinh $\rightarrow$ Học Tăng cường	Dùng mô hình tạo sinh làm thành phần trong Học Tăng cường
Học Tăng cường $\rightarrow$ AI Tạo sinh	Nhìn tương tác Học Tăng cường như một quá trình tạo sinh
Học Tăng cường để huấn luyện AI Tạo sinh	Dùng Học Tăng cường để cải thiện cách huấn luyện mô hình tạo sinh

1.3. Tầm quan trọng và tính thời sự

1.3.1. Ứng dụng thực tiễn

Sự kết hợp giữa AI Tạo sinh và Học Tăng cường có nhiều ứng dụng thực tiễn quan trọng [4] [15]:

Robot học: Diffusion policies đã đạt kết quả tốt nhất trong nhiều tác vụ điều khiển robot. Kết hợp với Học Tăng cường, robot có thể vượt qua giới hạn của dữ liệu minh họa, tự học cách thực hiện các hành vi chưa từng được quan sát.

Mô hình Nền tảng Hành vi: Tương tự như GPT là mô hình nền tảng cho ngôn ngữ, các Mô hình Nền tảng Hành vi (được học thông qua Học Tăng cường không có phần thưởng) có thể đóng vai trò mô hình nền tảng cho hành động, một model dùng được cho nhiều tác vụ robot khác nhau mà không cần huấn luyện lại.

Học Tăng cường từ Phản hồi Con người và Căn chỉnh AI: Học Tăng cường từ Phản hồi Con người (RLHF) – kỹ thuật cốt lõi làm cho ChatGPT “nghe lời” – là ứng dụng trực tiếp của Học Tăng cường để tinh chỉnh mô hình tạo sinh. Hiểu sâu mối liên hệ này giúp thiết kế các phương pháp căn chỉnh tốt hơn.

Khoa học và khám phá: AlphaFold dự đoán cấu trúc protein, AlphaProof giải bài thi toán Olympiad. Các hệ thống này đều dùng Học Tăng cường để tìm giải pháp mà không có dữ liệu tương ứng từ trước.

1.3.2. Tổng quát hóa – bài toán còn bỏ ngỏ

Tutorial đặt ra một câu hỏi quan trọng về tương lai: điều gì làm cho mô hình tạo sinh hình ảnh và mô hình ngôn ngữ trở nên ấn tượng không phải là chúng ghi nhớ dữ liệu đã thấy, mà là chúng *tổng quát hóa*, tức tạo ra output đúng trên những input chưa bao giờ thấy trong training.

Trong khi đó, các tác nhân Học Tăng cường ngày nay phần lớn vẫn chỉ ghi nhớ thay vì tổng quát hóa. Tutorial đặt câu hỏi: tương tự như một mô hình tạo sinh hình ảnh có thể tạo ra ảnh sống động sau khi chỉ thấy một phần nhỏ các ảnh có thể, liệu ta có thể xây dựng các tác nhân Học Tăng cường có thể giải quyết các bài toán mới sau khi chỉ practice trên một phần nhỏ không gian bài toán đó? Đây chính là *biên giới tổng quát hóa* mà kết hợp AI Tạo sinh và Học Tăng cường hướng tới.

1.4. Cấu trúc báo cáo

Báo cáo được tổ chức thành các phần chính như sau:

- **Phần 2** trình bày kiến thức nền về Học Tăng cường và Mô hình Tạo sinh, các khái niệm cơ sở cần thiết để hiểu nội dung tutorial.
- **Phần 3** trình bày nội dung chính của tutorial, bao gồm Phần I (Mô hình Tạo sinh trong Học Tăng cường), Phần II (Tương tác như một Mô hình Tạo sinh), Phần III (Học Hàm Khả năng) và Phần IV (Dữ liệu Tự Sinh).

- **Phần 4** mô tả thực nghiệm và kết quả demo nhóm thực hiện.
- **Phần 5** đánh giá ưu nhược điểm của các phương pháp và thảo luận hướng nghiên cứu tương lai.


2. Kiến thức nền

2.1. Học Tăng cường

2.1.1. Vòng lặp Tác nhân–Môi trường: Bức tranh tổng thể

Trước khi đi vào công thức toán học, hãy hình dung Học Tăng cường hoạt động như thế nào theo trực giác. Trong Học Tăng cường, một **tác nhân** (ví dụ: robot, chương trình chơi game, hệ thống điều khiển) liên tục tương tác với một **môi trường** (*environment*) theo vòng lặp lặp đi lặp lại:

1. Tác nhân quan sát **trạng thái hiện tại** s_t của môi trường (ví dụ: hình ảnh màn hình game, vị trí các khớp robot).
2. Tác nhân chọn một **hành động** a_t dựa trên *chính sách* (chiến lược) của mình (ví dụ: nhảy, đi thẳng, xoay trái).
3. Môi trường chuyển sang **trạng thái mới** s_{t+1} theo xác suất $p(s_{t+1} | s_t, a_t)$, đồng thời phát ra **tín hiệu phần thưởng** $r_t = r(s_t, a_t)$ (ví dụ: +1 mỗi khi xóa được một dòng trong Tetris, -1 khi robot ngã).
4. Lặp lại từ bước 1.



Hình 1: Vòng lặp tác nhân–môi trường trong Học Tăng cường. Tác nhân gửi hành động cho môi trường; môi trường phản hồi trạng thái mới và phần thưởng. Mục tiêu tác nhân là học chính sách π tối đa hóa tổng phần thưởng tích lũy.

Điểm khác biệt căn bản so với Học Có Giám sát là: **không có “đáp án đúng” nào được cung cấp sẵn**. Tác nhân phải tự khám phá thông qua thử-và-sai, và tín hiệu học duy nhất là phần thưởng thừa thớt từ môi trường. Điều này đồng thời là điểm mạnh (tác nhân có thể tìm ra chiến lược vượt trội hơn bất kỳ dữ liệu huấn luyện nào) và là thách thức chính của Học Tăng cường.

2.1.2. Định nghĩa bài toán Học Tăng cường: Quá trình Quyết định Markov

Bài toán Học Tăng cường được hình thức hóa bằng khung **Quá trình Quyết định Markov (MDP)**, bao gồm năm thành phần:

$$\text{MDP} = (\mathcal{S}, \mathcal{A}, p, r, \gamma) \quad (2)$$

Bảng 3: Các thành phần của Quá trình Quyết định Markov, minh họa qua game Tetris.

Ký hiệu	Tên	Ví dụ (Tetris)
$\mathcal{S}$	Không gian trạng thái	Mọi cấu hình bảng có thể
$\mathcal{A}$	Không gian hành động	{trái, phải, xoay, thả}
$p(s' s, a)$	Hàm chuyển trạng thái	Xác suất khối rơi vào ô nào
$r(s, a)$	Hàm phần thưởng	+1 mỗi dòng xóa được
$\gamma \in [0, 1)$	Hệ số chiết khấu	Thường từ 0.9 đến 0.999

Giả định **Markov** là nền tảng quan trọng của khung này: trạng thái hiện tại s_t chứa đủ thông tin để quyết định hành động tiếp theo, không cần nhớ toàn bộ lịch sử. Nói cách khác, “quá khứ” chỉ ảnh hưởng đến tương lai thông qua trạng thái hiện tại. Nhờ tính Markov, ta có thể dùng các phương trình đệ quy (phương trình Bellman) để tính toán hiệu quả thay vì phải xét toàn bộ lịch sử.

2.1.3. Chính sách và Mục tiêu Học Tăng cường

Chính sách π là chiến lược ra quyết định của tác nhân, hay một hàm ánh xạ từ trạng thái sang hành động (hoặc phân phối trên hành động):

$$\pi(a | s) = \text{xác suất chọn hành động } a \text{ khi ở trạng thái } s$$

Ví dụ: chính sách của người chơi Tetris giỏi sẽ gán xác suất cao cho hành động “xoay” khi nhìn thấy khối L ở vị trí nhất định.

Một **quỹ đạo** $\tau = (s_0, a_0, s_1, a_1, \dots)$ là chuỗi trạng thái và hành động theo thời gian, về bản chất là một “ván chơi” hoàn chỉnh. **Lợi tức chiết khấu** $R(\tau)$ là tổng

phần thưởng có chiết khấu theo thời gian:

$$R(\tau) = \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \quad (3)$$

Hệ số chiết khấu $\gamma < 1$ giải quyết hai vấn đề: nó đảm bảo tổng phần thưởng hội tụ (không vô hạn), đồng thời phản ánh nguyên tắc kinh tế học rằng phần thưởng gần hơn có giá trị hơn (giống như tiền ngày hôm nay có giá trị hơn tiền ngày mai).

Mục tiêu Học Tăng cường là tìm chính sách π tối đa hóa lợi tức kỳ vọng, tức phần thưởng tích lũy kỳ vọng trên tất cả các quỹ đạo có thể xảy ra:

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} [R(\tau)] = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right] \quad (4)$$

Ký hiệu $\tau \sim \pi$ nghĩa là quỹ đạo được sinh ra bởi chính sách π tương tác với môi trường: tại mỗi bước t , tác nhân chọn $a_t \sim \pi(\cdot \mid s_t)$, môi trường phản hồi $s_{t+1} \sim p(\cdot \mid s_t, a_t)$.

2.1.4. So sánh Học Tăng cường và Học Có Giám sát

Sự khác biệt căn bản giữa Học Tăng cường (HTc) và Học Có Giám sát (HG) nằm ở nguồn gốc dữ liệu:

$$\text{HG: } \max_{\theta} \mathbb{E}_{(s,a) \sim \mathcal{D}} [\log \pi_{\theta}(a \mid s)] \quad (5)$$

$$\text{HTc: } \max_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau)] \quad (6)$$

Trong HGs, dữ liệu đến từ tập dữ liệu cố định $\mathcal{D}$ và không phụ thuộc vào tham số đang học. Trong HTc, quỹ đạo được sinh ra bởi chính sách π_{θ} đang được tối ưu: khi θ thay đổi, cả phân phối hành động lẫn phân phối trạng thái được ghé thăm đều thay đổi theo. Đây chính là điểm mạnh (tác nhân có thể khám phá) nhưng cũng là thách thức chính (dữ liệu *không dừng*) của Học Tăng cường.

Ví dụ trực quan: nếu dùng HG để học chơi Tetris trên tập dữ liệu từ người chơi mới bắt đầu, model sẽ không thể giỏi hơn người đó. Nhưng với HTc, tác nhân tự tạo dữ liệu thông qua tương tác và có thể tìm ra chiến lược tốt hơn bất kỳ dữ liệu nào trong tập dữ liệu [7].

2.1.5. Hàm Giá trị và Phương trình Bellman

Để tối ưu $J(\pi)$, cần biết “từ trạng thái này, hành động nào dẫn đến lợi tức cao nhất?”. Đây là vai trò của **hàm giá trị**.

Hàm Q $Q^\pi(s, a)$ cho biết lợi tức kỳ vọng khi bắt đầu từ cặp (s, a) và sau đó theo chính sách π :

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a \right] \quad (7)$$

Diễn giải đơn giản: $Q^\pi(s, a)$ trả lời câu hỏi “Nếu tôi đang ở trạng thái s , thực hiện hành động a , rồi từ đó trở đi luôn theo chính sách π , tôi kỳ vọng nhận được bao nhiêu phần thưởng tổng cộng?”

Hàm Q thỏa **phương trình Bellman** – quan hệ đệ quy cơ bản của Học Tăng cường. Phương trình này phát biểu rằng giá trị hiện tại bằng phần thưởng ngay lập tức cộng với giá trị tương lai được chiết khấu:

$$Q^\pi(s, a) = \underbrace{r(s, a)}_{\text{thưởng ngay}} + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a), a' \sim \pi(\cdot | s')} \left[\underbrace{Q^\pi(s', a')}_{\text{giá trị tương lai}} \right] \quad (8)$$

Phương trình Bellman quan trọng vì nó biến bài toán tối ưu hóa vô hạn chiều thành bài toán có thể giải lặp đi lặp lại (quy hoạch động). Hàm Q xuất hiện xuyên suốt tutorial: trong chính sách khuếch tán (dùng Q để chọn hành động), trong học tương phản thời gian ($Q \approx$ tỉ lệ log-likelihood), và trong Học Tăng cường không cần huấn luyện lại (tính Q từ biểu diễn học được).

2.1.6. Gradient Chính sách

Để tối đa hóa $J(\pi_\theta)$, ta lấy gradient theo tham số θ và thực hiện leo dốc gradient. Định lý Gradient Chính sách cho kết quả:

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[R(\tau) \cdot \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right] \quad (9)$$

Trực giác của gradient chính sách rất tự nhiên: số hạng $\nabla_\theta \log \pi_\theta(a | s)$ đẩy tham số theo hướng tăng xác suất của hành động a tại trạng thái s ; nhân với $R(\tau)$ nghĩa là ta tăng xác suất của những hành động đã dẫn đến lợi tức cao, và giảm xác suất của những hành động dẫn đến lợi tức thấp.

Số hạng $\nabla_{\theta} \log \pi_{\theta}(a | s)$ được gọi là **hàm điểm số** của chính sách. Đây là cầu nối kỹ thuật quan trọng nhất giữa Học Tăng cường và mô hình tạo sinh: trong các mô hình khuếch tán dựa trên điểm số, đại lượng tương tự $\nabla_x \log p(x)$ được dùng để hướng dẫn quá trình sinh mẫu. Hai bài toán tối ưu chính sách và sinh mẫu từ mô hình tạo sinh đều có thể được giải qua cùng một công cụ toán học: **theo dõi gradient của log-xác suất**.

2.2. Mô hình Tạo sinh

2.2.1. Tổng quan và Phân loại

Mô hình tạo sinh là mô hình có khả năng (1) tạo ra mẫu mới từ một phân phối học được, và (2) ước lượng hàm khả năng (xác suất) của các mẫu đã cho. Khác với các mô hình phân biệt (phân loại đầu vào), mô hình tạo sinh học phân phối xác suất $p(x)$ của dữ liệu và có thể sinh ra mẫu mới $x \sim p(x)$.

Ý tưởng chung của các mô hình tạo sinh mạnh nhất hiện nay là thực hiện **tính toán lặp đi lặp lại** để tạo ra mẫu:

- **VAE** và luồng chuẩn hóa biến đổi vector nhiễu qua nhiều lớp mạng neural.
- **Mô hình khuếch tán** lặp đi lặp lại quá trình khử nhiễu qua hàng trăm bước.
- **Transformer** sinh token từng bước một theo thứ tự.
- **Mô hình khớp luồng** tích phân một trường vector để biến đổi phân phối.

Đặc điểm “nhiều bước” này không phải ngẫu nhiên, nó phản ánh một nguyên lý sâu xa: các phân phối phức tạp rất khó nắm bắt trong một bước duy nhất, nhưng lại có thể được xây dựng dần dần qua nhiều bước đơn giản hơn. Tutorial chỉ ra rằng **đây chính là điểm tương đồng với Học Tăng cường**: một tác nhân Học Tăng cường cũng tạo ra kết quả thông qua nhiều bước tương tác với môi trường.

2.2.2. Bộ Mã hóa Biến phân (VAE)

VAE là một trong những mô hình tạo sinh đầu tiên học được không gian tiềm ẩn (latent space) ý nghĩa. VAE gồm hai thành phần: bộ mã hóa $q_{\phi}(z | x)$ nén dữ liệu x vào vector tiềm ẩn z , và bộ giải mã $p_{\theta}(x | z)$ tái tạo dữ liệu từ z . Quá trình sinh mẫu mới đơn giản là lấy mẫu $z \sim \mathcal{N}(0, I)$ rồi cho qua bộ giải mã.

VAE được huấn luyện bằng cách tối đa hóa ELBO (Cận dưới Bằng chứng):

$$\mathcal{L}_{\text{VAE}} = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \parallel \mathcal{N}(0, I)) \quad (10)$$

Số hạng đầu khuyến khích bộ giải mã tái tạo tốt; số hạng KL chính quy hóa không gian tiềm ẩn về phân phối Gaussian chuẩn.

Kết nối với Học Tăng cường: Trong học kỹ năng (Phần IV của tutorial), biến tiềm ẩn z của VAE tương đồng chính xác với “nhân kỹ năng” z – một biến điều kiện quyết định loại hành vi tác nhân thực hiện. Cả hai đều nén thông tin về một tập hành vi phức tạp vào một không gian nhỏ hơn có thể tìm kiếm được.

2.2.3. Mạng Đối kháng Tạo sinh (GAN)

GAN gồm hai mạng thi đấu với nhau theo dạng trò chơi minimax: *bộ tạo sinh* G cố gắng sinh mẫu giống thật, *bộ phân biệt* D cố gắng phân biệt mẫu thật với mẫu giả:

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim \mathcal{N}(0, I)} [\log(1 - D(G(z)))] \quad (11)$$

Khi đạt cân bằng Nash, bộ tạo sinh học được phân phối dữ liệu thật.

Kết nối với Học Tăng cường: Bộ phân biệt của GAN có thể được tái sử dụng trực tiếp làm **tín hiệu phần thưởng** cho Học Tăng cường. Nếu bộ phân biệt học được “mẫu này trông như thật không”, ta có thể dùng $\log D(x)$ làm phần thưởng để dạy tác nhân thực hiện hành vi trông tự nhiên. Đây là một trong những cách phá vỡ “rào cản trù trù tượng hóa” giữa mô hình tạo sinh và thuật toán Học Tăng cường mà tutorial nhấn mạnh.

2.2.4. Mô hình Khuếch tán

Mô hình khuếch tán là họ mô hình tạo sinh hiện đại nhất, đứng sau các hệ thống tạo ảnh mạnh nhất hiện nay như Stable Diffusion và DALL-E. Ý tưởng cốt lõi: **học cách đảo ngược một quá trình phá hủy**.

Quá trình tiến (thêm nhiễu). Bắt đầu từ dữ liệu sạch x_0 , ta dần dần thêm nhiễu Gaussian qua T bước để thu được chuỗi $x_1, x_2, \dots, x_T$, trong đó x_T gần với nhiễu trắng hoàn toàn:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t \mathbf{I})$$

Nhờ tính chất của Gaussian, ta có thể tính thẳng x_t từ x_0 :

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) \mathbf{I}), \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$$

Quá trình ngược (khử nhiễu). Mô hình học cách đảo ngược quá trình trên, từ x_T nhiễu, dần dần tái tạo dữ liệu sạch x_0 qua nhiều bước. Đây là bước khó vì cần ước lượng $p(x_{t-1} | x_t)$. Kỹ thuật mấu chốt là học **hàm điểm số**:

$$s_\theta(x_t, t) \approx \nabla_{x_t} \log p_t(x_t)$$

Hàm điểm số $\nabla_{x_t} \log p_t(x_t)$ là gradient của log-xác suất theo x_t , nó chỉ hướng “đi về phía vùng mật độ xác suất cao hơn” trong không gian dữ liệu tại bước thời gian t .

Kết nối với Học Tăng cường: Hàm điểm số của mô hình khuếch tán $\nabla_x \log p_t(x)$ và hàm điểm số của gradient chính sách $\nabla_\theta \log \pi_\theta(a | s)$ là cùng một cấu trúc toán học – gradient của log-xác suất theo biến cần tối ưu. Đây là lý do mô hình khuếch tán và gradient chính sách có thể được tích hợp tự nhiên vào nhau, như được minh họa qua DDPO và Diffusion-DICE ở Phần III.

Trong Học Tăng cường, mô hình khuếch tán được dùng làm **chính sách khuếch tán**: thay vì chính sách Gaussian đơn giản chỉ biểu diễn một đỉnh, tác nhân dùng một mô hình khuếch tán để biểu diễn phân phối hành động phức tạp, đa đỉnh, điều này quan trọng khi tập dữ liệu chứa nhiều chiến lược khác nhau.

2.2.5. Mô hình Khớp Luồng

Khớp luồng là một hướng tiếp cận thay thế cho khuếch tán, học cách biến đổi trực tiếp một phân phối đơn giản (thường là Gaussian) thành phân phối dữ liệu thông qua một **trường vector** $v_\theta(x, t)$ có thể học được. Quá trình biến đổi được mô tả bởi phương trình vi phân thường (ODE):

$$\frac{dx}{dt} = v_\theta(x, t), \quad x(0) \sim \mathcal{N}(0, I), \quad x(1) \sim p_{\text{data}} \quad (12)$$

Ý tưởng trực quan: ta “vẽ” một đường đi trơn trong không gian xác suất, từ điểm xuất phát (nhiều Gaussian) đến điểm đích (dữ liệu thật). Trường vector v_θ chỉ hướng và tốc độ di chuyển tại mỗi điểm.

Ưu điểm so với khuếch tán. Mô hình khuếch tán dùng lịch trình nhiễu cố định với hàng trăm bước nhỏ. Khớp luồng học đường đi **thẳng hơn** trong không gian xác suất, cho phép sinh mẫu với ít bước hơn (đôi khi chỉ 1 bước ODE). Về lý thuyết, khớp luồng tối ưu hóa trực tiếp hàm khả năng của quỹ đạo thay vì phải thông qua các bước gián tiếp.

Kết nối với Học Tăng cường: Trong tutorial, Luồng Hiệu chỉnh Thời gian [8] áp dụng khớp luồng để ước lượng *hàm khả năng của trạng thái tương lai*, tức thước đo

kế tiếp, kết hợp với cấu trúc Bellman để tận dụng dữ liệu ngoài chính sách. Đây là ví dụ điển hình về việc khai thác đặc thù của một họ mô hình tạo sinh để giải quyết bài toán Học Tăng cường.

2.2.6. Transformer và Mô hình Tự Hồi quy

Transformer là kiến trúc mạng neural dựa trên cơ chế *tự chú ý*, hiện đang chi phối phần lớn AI hiện đại (GPT, BERT, ViT). Trước khi giải thích ứng dụng trong Học Tăng cường, cần hiểu hai khái niệm cốt lõi:

Tự chú ý. Với một chuỗi token $(x_1, \dots, x_n)$, tự chú ý tính **mức độ liên quan** giữa mỗi cặp token và tổng hợp thông tin theo mức độ đó:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

trong đó Q (truy vấn), K (khóa), V (giá trị) là các biến đổi tuyến tính của đầu vào. Cơ chế này cho phép mỗi token “chú ý” đến những token liên quan nhất, bất kể chúng cách nhau bao xa trong chuỗi – điều mà RNN và LSTM gặp khó khăn.

Mô hình tự hồi quy. Mô hình tự hồi quy sinh chuỗi token từng bước một, trong đó mỗi token được sinh có điều kiện trên toàn bộ các token đã sinh trước đó:

$$p(x_1, x_2, \dots, x_T) = \prod_{t=1}^T p(x_t \mid x_1, \dots, x_{t-1})$$

Đây là nguyên tắc hoạt động của GPT: sinh token tiếp theo dựa trên tất cả token trước đó.

Transformer Quyết định: mô hình tự hồi quy làm chính sách. **Transformer Quyết định** [3] áp dụng trực tiếp kiến trúc này cho Học Tăng cường: thay vì học hàm giá trị hay thực hiện cập nhật Bellman, mô hình coi một quỹ đạo Học Tăng cường – chuỗi $(R_0, s_0, a_0, R_1, s_1, a_1, \dots)$ – như một chuỗi token và học sinh hành động có điều kiện trên *lợi tức-còn-lại* (tổng phần thưởng kỳ vọng từ bước hiện tại trở đi) và lịch sử quỹ đạo.

Ý tưởng then chốt: nếu ta điều kiện hóa mô hình trên “lợi tức mục tiêu cao” (ví dụ: 100 điểm), model sẽ sinh ra những hành động từng được quan sát trong các quỹ đạo có lợi tức cao. Đây là ví dụ điển hình của việc dùng mô hình tạo sinh làm chính sách trong Học Tăng cường.

2.3. Thước đo Kế tiếp

Thước đo kế tiếp (hay thước đo chiếm dụng trạng thái chiết khấu) $p^\pi(s_f)$ là một trong những khái niệm xuyên suốt toàn bộ tutorial. Nó được định nghĩa là xác suất mà tác nhân đến được trạng thái s_f tại một thời điểm nào đó trong tương lai khi theo chính sách π :

$$p^\pi(s_f) \triangleq (1 - \gamma) \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t p(s_{t+1} = s_f \mid s_t, a_t) \right] \quad (13)$$

Hệ số $(1 - \gamma)$ chuẩn hóa để p^π là một phân phối xác suất hợp lệ (tổng bằng 1). Phiên bản có điều kiện $p^\pi(s_f \mid s, a)$ cho biết xác suất đến s_f khi bắt đầu từ trạng thái s và thực hiện hành động a .

2.3.1. Ý nghĩa trực quan và ví dụ minh họa

Thước đo kế tiếp trả lời câu hỏi: “Nếu tác nhân bắt đầu từ trạng thái s và theo chính sách π , nó có bao nhiêu khả năng ghé thăm trạng thái s_f trong tương lai?” Khái niệm này **tổng quát hóa hàm Q**: trong khi hàm Q tính *một số* (tổng phần thưởng kỳ vọng), thước đo kế tiếp tính *một phân phối đầy đủ* trên các trạng thái tương lai.

Ví dụ minh họa bằng mê cung 3×3 . Hãy tưởng tượng robot đứng tại ô (1, 1) trong mê cung 3×3 , với chính sách “luôn đi thẳng về phía đông”. Thước đo kế tiếp $p^\pi(s_f \mid (1, 1), \text{đi đông})$ với $\gamma = 0.9$ sẽ trông như sau (giá trị xấp xỉ):

ô (1, 1)	ô (1, 2): 0.36 (sau 1 bước: $0.9^0 \cdot 0.4$)	ô (1, 3): 0.32 (sau 2 bước)
... xác suất thấp dần ở các ô phía sau ...		

Khác với hàm Q chỉ cho biết “tổng reward kỳ vọng là bao nhiêu”, thước đo kế tiếp cho biết *tác nhân sẽ ở đâu* – thông tin phong phú hơn. Lợi ích then chốt: nếu phần thưởng thay đổi (ví dụ: bây giờ ô (1, 3) có thưởng thay vì ô (1, 2)), ta chỉ cần tính lại tích phân trên thước đo kế tiếp đã học, **không cần train lại từ đầu**.

2.3.2. Liên hệ với Hàm Q

Kết nối giữa thước đo kế tiếp và hàm Q rất trực tiếp. Nếu có thước đo kế tiếp $p^\pi(s_f \mid s, a)$ và tập trạng thái có nhãn thưởng $r(s_f)$, ta có thể tính hàm Q bằng:

$$Q^\pi(s, a) = \mathbb{E}_{s_f \sim p^\pi(\cdot | s, a)} [r(s_f)] = \int r(s_f) p^\pi(s_f | s, a) ds_f \quad (14)$$

Điều này có ý nghĩa lớn: nếu học được thước đo kế tiếp một lần, ta có thể tính hàm Q cho **bất kỳ hàm thưởng nào** mà không cần huấn luyện lại. Đây là nền tảng cho Học Tăng cường không cần huấn luyện lại được trình bày trong Phần III.

2.3.3. Tính toán qua Bellman

Thước đo kế tiếp thỏa mãn một phương trình Bellman tương tự hàm Q :

$$p^\pi(s_f | s, a) = (1 - \gamma) p(s' = s_f | s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a), a' \sim \pi(\cdot | s')} [p^\pi(s_f | s', a')] \quad (15)$$

Diễn giải: xác suất đến s_f từ (s, a) bằng xác suất đến s_f *ngay bước tiếp theo* (số hạng đầu) cộng với xác suất đến s_f *sau nhiều bước* thông qua trạng thái trung gian s' (số hạng sau).

Tính chất này cho phép ước lượng thước đo kế tiếp từ dữ liệu ngoài chính sách bằng học hiệu chỉnh thời gian, tương tự như cách ta ước lượng hàm Q . Đây là lý do thước đo kế tiếp có thể được học hiệu quả từ dữ liệu tương tác.

2.3.4. Vị trí trong Tutorial

Thước đo kế tiếp xuất hiện ở nhiều phần khác nhau của tutorial với các vai trò đa dạng. Trong Phần II, nó mô tả phân phối trạng thái đích của bài toán đạt đích. Trong Phần III, nó là hàm khả năng của “mô hình tạo sinh tương tác” cần được ước lượng. Trong Học Tăng cường không cần huấn luyện lại, các biểu diễn tiến-lùi học cách phân tích thước đo kế tiếp để cho phép tính chính sách tối ưu cho bất kỳ hàm thưởng nào chỉ trong vài bước tính toán.

2.4. Bảng đối chiếu Học Tăng cường và Mô hình Tạo sinh

Một trong những đóng góp quan trọng nhất của tutorial là chỉ ra sự tương đương toán học giữa Học Tăng cường và Mô hình Tạo sinh. Bảng 4 tổng hợp các khái niệm tương ứng giữa hai lĩnh vực. Mỗi hàng trong bảng thể hiện một cặp khái niệm đóng *cùng một vai trò toán học* trong hai lĩnh vực khác nhau. Hiểu bảng này giúp giải thích tại sao kỹ thuật từ lĩnh vực này có thể áp dụng cho lĩnh vực kia.

Một số cặp chưa quen thuộc sẽ được giải thích trong Phần III: *thước đo chiếm*

dùng $d^\pi(s, a)$ là phân phối tần suất trạng thái-hành động mà chính sách ghé thăm (tổng quát hóa thước đo kế tiếp sang không gian trạng thái-hành động); *tỉ lệ hàm khả năng* là tỉ số $p^\pi(s_f | s, a)/p(s_f)$ đo mức độ chính sách tăng xác suất đến s_f so với đường cơ sở.

Bảng 4: Các khái niệm tương đương giữa Học Tăng cường và Mô hình Tạo sinh.

Học Tăng cường	Mô hình Tạo sinh	Ý nghĩa chung
Chính sách $\pi(a s)$	Mô hình tạo sinh $p(x)$	Phân phối cần học
Hàm điểm số $\nabla_\theta \log \pi(a s)$	Hàm điểm số $\nabla_x \log p(x)$	Gradient của log-xác suất
Lợi tức $R(\tau)$	Log-hàm khả năng $\log p(x)$	Tín hiệu học
Quỹ đạo τ	Biến tiềm ẩn z	Biến tiềm ẩn
Gradient chính sách	Ước lượng hàm điểm số	Cách tối ưu phân phối
Hàm Q $Q(s, a)$	Tỉ lệ hàm khả năng $\frac{p^\pi(s_f s, a)}{p(s_f)}$	Ước lượng xác suất tương lai
Thước đo chiếm dụng $d^\pi(s, a)$	Phân phối dữ liệu $p(x)$	Phân phối muốn khớp
Phương trình Bellman	Tính chất Markov	Cấu trúc đệ quy
Nhãn kỹ năng z	Mã tiềm ẩn z trong VAE	Điều khiển hành vi

Hiểu bảng này giúp đọc phần nội dung chính dễ hơn đáng kể: mỗi khi tutorial dùng kỹ thuật từ một lĩnh vực để giải quyết bài toán của lĩnh vực kia, đều có thể truy về một cặp tương đương trong bảng 4.

3. Nội dung chính của bài hướng dẫn

Trước khi đi vào từng kỹ thuật, các công trình chính trong phần này được định vị theo vai trò mà chúng đảm nhiệm trong mạch lập luận của bài hướng dẫn. Mỗi công trình không được trình bày như một mục tổng thuật tài liệu riêng. Thay vào đó, từng công trình được dùng để xử lý một nút thắt kỹ thuật cụ thể: học dynamics, biểu diễn chính sách, kiểm soát khai thác lỗi, tinh chỉnh diffusion model bằng reward, hoặc chuyển tương tác thành khớp phân phối.

Công trình / vai trò	Kỹ thuật chính	Điểm cần rút ra
PILCO, PETS, Dreamer, Diffuser Mô hình thế giới trong RL dựa trên mô hình	Học dynamics bằng conditional likelihood hoặc model quỹ đạo	Giảm chi phí tương tác, nhưng chịu rủi ro rollout error và model exploitation
Decision Transformer Mô hình chuỗi làm chính sách	Conditioning chính sách trên return-to-go và history quỹ đạo	Minh họa chính sách tạo sinh trong offline RL, nhưng dễ học correlation thay vì causal effect
Diffusion-DICE Chính sách khuếch tán trong offline RL	Guide-then-select với density-ratio guidance và chọn candidate bằng Q	Khai thác biểu diễn đa mode của diffusion mà giảm khai thác lỗi
DDPO Tinh chỉnh diffusion model bằng RL	Xem chain khử nhiễu như finite-horizon MDP và tối ưu bằng gradient chính sách	Cho thấy chiều ngược lại: RL có thể tối ưu chính generative model theo downstream reward
GCBC, Học tăng cường song nguyên, DICE, f-Policy Gradients Quá trình tương tác như một mô hình tạo sinh	Goal conditioning, occupancy matching, tỉ lệ mật độ và gradient f -divergence	Thay thiết kế reward bằng mục tiêu trên phân phối, nhưng vẫn phụ thuộc miền hỗ trợ và độ ổn định ước lượng

Bảng 5: Các công trình chính trong Phần I và Phần II được nhóm theo vai trò kỹ thuật trong mạch lập luận.

3.1. Mô hình tạo sinh trong hệ thống học tăng cường

3.1.1. So sánh mục tiêu học có giám sát và mục tiêu RL

Điểm xuất phát của phân tích là sự khác biệt giữa học có giám sát và học tăng cường. Trong học có giám sát, bộ dữ liệu được xem như cố định. Nếu học một chính sách bằng imitation learning, dữ liệu gồm các cặp trạng thái–hành động (s, a) từ chuyên gia hoặc từ một hệ thống có sẵn. Mô hình được tối ưu để tăng likelihood của hành

động trong bộ dữ liệu:

$$\max_{\theta} J_{\text{SL}}(\theta) = \mathbb{E}_{(s,a) \sim \mathcal{D}} [\log \pi_{\theta}(a \mid s)]. \quad (16)$$

Mục tiêu này có bản chất là tái tạo hành vi quan sát được. Trong trường hợp chính sách Gaussian với phương sai cố định, maximum likelihood tương đương với việc giảm sai số bình phương giữa hành động dự đoán và hành động trong bộ dữ liệu. Vì vậy, chất lượng chính sách phụ thuộc trực tiếp vào chất lượng dữ liệu. Nếu bộ dữ liệu đến từ một chính sách yếu hoặc không bao phủ những hành vi tốt, mục tiêu học có giám sát không tự tạo ra cơ chế để vượt ra khỏi giới hạn đó.

Trong RL, mô hình không chỉ học từ dữ liệu có sẵn mà còn quyết định dữ liệu nào sẽ được sinh ra. Bài toán thường được hình thức hóa bằng một Markov Decision Process gồm state s_t , action a_t , dynamics $p(s_{t+1} \mid s_t, a_t)$, reward $r(s_t, a_t)$ và discount factor γ . Một quỹ đạo có dạng $\tau = (s_0, a_0, s_1, a_1, \dots)$, với return chiết khấu:

$$R(\tau) = \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t). \quad (17)$$

Mục tiêu của RL đánh giá chính sách theo expected discounted return qua các quỹ đạo mà chính sách sinh ra:

$$J_{\text{RL}}(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau)]. \quad (18)$$

Khác biệt then chốt nằm ở phân phối lấy kỳ vọng. Trong Phương trình (16), dữ liệu đến từ $\mathcal{D}$ và không phụ thuộc vào tham số chính sách đang học. Trong Phương trình (18), quỹ đạo lại được sinh bởi chính π_{θ} khi chính sách tương tác với environment. Khi θ thay đổi, phân phối hành động thay đổi, phân phối trạng thái được ghé thăm cũng thay đổi, và do đó phân phối dữ liệu huấn luyện trong tương lai cũng thay đổi.

Do phân phối quỹ đạo phụ thuộc vào chính sách, tối ưu RL đồng thời thay đổi quy tắc ra quyết định và phân phối dữ liệu mà quy tắc đó sẽ gặp trong tương lai. Khác với học có giám sát trên phân phối cố định, sai lệch của chính sách có thể làm thay đổi chính miền trạng thái dùng để đánh giá và cập nhật chính sách. Đặc điểm phân phối này tạo ra mối liên hệ trực tiếp với mô hình hóa tạo sinh. Tuy nhiên, RL có thêm một ràng buộc riêng: phân phối sinh ra phải được đánh giá thông qua reward và dynamics của môi trường.

3.1.2. Mô hình tạo sinh làm mô hình thế giới

Vai trò trực tiếp nhất của generative models trong RL là mô hình thế giới. Trong nhiều bài toán như robotics, điều khiển hệ thống vật lý, thiết kế phân tử hoặc tương tác với người dùng thật, thu thập dữ liệu bằng cách chạy chính sách trong môi trường có thể chậm, tốn kém hoặc nguy hiểm. Model-based RL giải quyết khó khăn này bằng cách học một mô hình dynamics:


$$p_{\phi}(s' \mid s, a) \approx p(s' \mid s, a). \quad (19)$$

Nếu có bộ dữ liệu chuyển trạng thái $\mathcal{D} = \{(s, a, s')\}$, mô hình thế giới có thể được học bằng maximum likelihood trên các tuple (s, a, s') :

$$\max_{\phi} \mathbb{E}_{(s,a,s') \sim \mathcal{D}} [\log p_{\phi}(s' \mid s, a)]. \quad (20)$$

Về mặt huấn luyện, đây là một bài toán conditional generative modeling: từ (s, a) , model sinh hoặc ước lượng distribution của state kế tiếp. Sau khi học được, mô hình thế giới có thể được dùng để rollout, đánh giá chính sách hoặc huấn luyện chính sách mà không cần tương tác trực tiếp với environment thật ở mọi bước.

Các công trình model-based RL được đặt trong phần này như các ví dụ về những generative model families có thể thay vào cùng formulation, thay vì là đối tượng khảo sát thuật toán chi tiết. Các lựa chọn tiêu biểu gồm Gaussian process trong **PILCO**, ensemble Gaussian MLP trong **PETS**, latent state-space model trong **Dreamer**, diffusion model trên quỹ đạo trong **Diffuser**, sequence model trong **Decision Transformer** và **Trajectory Transformer**, cùng flow-matching model trong **Temporal Difference Flows** [6, 5, 9, 11, 3, 12, 8]. Danh sách này cho thấy “mô hình thế giới” không chỉ định một architecture cụ thể: model family được lựa chọn quyết định cách biểu diễn uncertainty, high-dimensional observation, multimodality và độ dài của rollout, trong khi vai trò chung vẫn là xấp xỉ dynamics để hỗ trợ planning hoặc học chính sách.



Hình 2: Pipeline model-based RL với mô hình thế giới: generative model được huấn luyện để học dynamics từ transition data, sau đó hỗ trợ học chính sách. Nguồn hình: Figure 3 trong [7].

Mô hình thế giới đem lại lợi ích rõ ràng về chi phí tính toán: rollout trong neural model có thể chạy theo batch trên GPU, trong khi simulator thật hoặc hệ thống vật lý thật có thể rất đắt. Lợi ích tính toán này chỉ có ý nghĩa khi sai số mô hình được kiểm soát trên rollout. Lỗi dự đoán một bước có thể tích lũy thành sai lệch lớn sau nhiều bước, và sai lệch đó còn nguy hiểm hơn khi chính sách học cách khai thác vùng mà model dự đoán quá lạc quan về reward hoặc dynamics. Do đó, mô hình thế giới không chỉ cần chính xác trung bình trên bộ dữ liệu ban đầu. Hệ thống còn cần cơ chế đánh giá độ tin cậy của model và quyết định khi nào phải thu thập thêm dữ liệu từ environment. Hệ quả là độ chính xác one-step chưa đủ để đánh giá mô hình thế giới. Độ tin cậy của model còn phụ thuộc vào sai số tích lũy trên rollout và vào phân phối trạng thái do chính sách đang tối ưu tạo ra.

3.1.3. Học có trọng số phần thưởng và hàm điểm số

Sau mô hình thế giới, câu hỏi nền tảng là dữ liệu trong RL đến từ đâu. Trong học có giám sát, bộ dữ liệu là đầu vào cố định và tồn tại độc lập với model đang học. Ngược lại, trong RL, chính chính sách quyết định dữ liệu nào sẽ được thu thập. Vì vậy, cải thiện chính sách và tạo dữ liệu mới là hai quá trình phụ thuộc lẫn nhau. Chính sách tốt cần quỹ đạo tốt để học, nhưng quỹ đạo tốt lại thường chỉ xuất hiện khi chính sách đã đủ tốt.

Quan hệ này có thể được hình thức hóa bằng một lower bound kiểu ELBO, trong đó quỹ đạo đóng vai trò latent variable. Gọi $\pi_\theta(\tau)$ là xác suất chính sách sinh quỹ đạo τ , và $R(\tau) > 0$ là return. Với một variational distribution $q(\tau)$ dương trên các quỹ đạo

được xét, ta nhân và chia integrand cho $q(\tau)$:

$$\begin{aligned}\log \mathbb{E}_{\pi_{\theta}(\tau)}[R(\tau)] &= \log \int \pi_{\theta}(\tau) R(\tau) d\tau \\ &= \log \int q(\tau) \frac{\pi_{\theta}(\tau) R(\tau)}{q(\tau)} d\tau.\end{aligned}\tag{21}$$

Phép biến đổi này không làm thay đổi expected return, nhưng đưa biểu thức về log của một kỳ vọng theo q , là dạng cần thiết để áp dụng Jensen. Giả thiết $R(\tau) > 0$ bảo đảm đối số của log dương. Nếu return không dương, phép suy diễn này không áp dụng trực tiếp. Khi đó cần xác định một hàm trọng số dương từ return, tức là mục tiêu tái trọng số cũng thay đổi tương ứng. Khi đó:

$$\log \mathbb{E}_{\pi_{\theta}(\tau)}[R(\tau)] \geq \mathbb{E}_{q(\tau)} [\log \pi_{\theta}(\tau) + \log R(\tau) - \log q(\tau)].\tag{22}$$

Dưới góc nhìn variational inference, quỹ đạo τ đóng vai trò như một latent variable. Đại lượng tương ứng với evidence trong phép diễn giải này là expected return $\mathbb{E}_{\pi_{\theta}(\tau)}[R(\tau)]$. Phương trình (22) xây dựng một lower bound cho log của đại lượng đó. Các quỹ đạo tạo ra return cao chưa được biết trước và được mô hình hóa thông qua variational distribution $q(\tau)$.



Hình 3: Diễn giải RL như một bài toán latent-variable. Các path dẫn đến high-reward state đóng vai trò latent variables cần được suy luận. Nguồn hình: Figure 6 trong [7].

Trong một bước coordinate update, ký hiệu $\pi_{\theta_{\text{old}}}$ là chính sách đã sinh batch quỹ đạo hiện tại. Tối ưu lower bound theo q với chính sách này được giữ cố định cho nghiệm:

$$q^*(\tau) = \frac{R(\tau)\pi_{\theta_{\text{old}}}(\tau)}{\int R(\tau')\pi_{\theta_{\text{old}}}(\tau')d\tau'}.\tag{23}$$

Phân phối q^* tái trọng số quỹ đạo của chính sách cũ theo return và không tạo xác suất trên các quỹ đạo nằm ngoài support đã được lấy mẫu. Vì vậy, policy update chỉ có thể nhấn mạnh các hành vi đã xuất hiện; khả năng khám phá vẫn quyết định những vùng quỹ đạo nào có thể được tối ưu ở bước kế tiếp.

Khi giữ q^* cố định và tối ưu chính sách mới, các hằng số chuẩn hóa không phụ thuộc vào θ có thể được bỏ qua. Sau khi giữ q^* cố định, reward-weighted regression tối

ưu likelihood của quỹ đạo dưới trọng số return:

$$\mathcal{L}_{\text{RWR}}(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta_{\text{old}}}} [R(\tau) \log \pi_{\theta}(\tau)]. \quad (24)$$

Do likelihood quỹ đạo phân rã theo các action, gradient của mục tiêu này có dạng:


$$\nabla_{\theta} \mathcal{L}_{\text{RWR}}(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta_{\text{old}}}} \left[R(\tau) \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]. \quad (25)$$

Kỳ vọng trong Phương trình (25) được lấy theo chính sách ở vòng trước, còn log-likelihood được tối ưu theo tham số chính sách mới. Đây là cấu trúc update trong phép suy diễn ELBO của tutorial: lấy mẫu quỹ đạo, cố định batch, gán trọng số bằng return và thực hiện maximum likelihood có trọng số [17].

Cần phân biệt estimator trên với gradient chính sách on-policy của expected return. Nếu lấy gradient trực tiếp của expected return thay vì tối ưu lower bound, ta thu được estimator gradient chính sách:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[R(\tau) \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]. \quad (26)$$

Số hạng $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ chính là hàm điểm số của chính sách. Sự xuất hiện của cùng hàm điểm số trong Phương trình (25) và Phương trình (26) là cầu nối kỹ thuật giữa RL và generative modeling: bất kỳ generative model family nào cho phép tính hoặc ước lượng score của action đều có thể được tích hợp vào cập nhật kiểu gradient chính sách [20]. Kết quả này không phụ thuộc vào giả thiết chính sách Gaussian; transformer, diffusion model và flow model khác nhau ở cách tham số hóa phân phối và xây dựng score estimator.



Hình 4: Sơ đồ cho thấy vai trò của hàm điểm số: cùng đại lượng $\nabla_{\theta} \log \pi_{\theta}$ xuất hiện trong gradient chính sách và trong generative model, nên chính sách tạo sinh có thể được cập nhật bằng tín hiệu RL.

3.1.4. Mô hình tạo sinh làm chính sách

Khi chính sách được nhìn như phân phối có điều kiện $\pi_\theta(a | s)$, chính chính sách đã là một generative model sinh action từ state. Ở mức kỹ thuật, các policy distribution đơn giản được thay bằng những kiến trúc sinh mạnh hơn, đặc biệt là sequence models và diffusion models.

Ghi chú bài giảng trước hết trừu tượng hóa hướng mô hình hóa chuỗi cho RL bằng cách xem quỹ đạo ngoại tuyến như một chuỗi trạng thái, hành động và phần thưởng [7]:

$$S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1}, \dots \quad (27)$$

Trong công trình **Decision Transformer**, ý tưởng này được cụ thể hóa bằng một autoregressive transformer không học hàm giá trị hoặc Bellman backup trực tiếp, mà học phân phối hành động có điều kiện trên return-to-go và lịch sử quỹ đạo [3]: $\pi(a_t | s_{\leq t}, a_{< t}, R_{\text{target}})$, thay cho conditioning chỉ trên state hiện tại. Giá trị return mục tiêu đóng vai trò biến điều kiện điều chỉnh phân phối hành động học được từ dữ liệu offline. Điểm mạnh của cách tiếp cận này là tận dụng năng lực sequence modeling đã thành công trong generative AI. Hạn chế là mô hình chủ yếu học correlation trong offline quỹ đạo. Nếu một quỹ đạo có return cao do may mắn trong môi trường stochastic, việc condition trên return cao có thể khiến mô hình bắt chước action không thực sự là nguyên nhân tạo ra reward cao [16]. Vì vậy, vai trò của **Decision Transformer** trong phần này không phải là thay thế toàn bộ RL bằng language modeling, mà là minh họa một policy class mới: chính sách được mô hình hóa như conditional sequence model. Nút thắt kỹ thuật mà công trình này làm rõ là sự khác biệt giữa biểu diễn một phân phối hành động phức tạp và bảo đảm policy improvement khi dữ liệu chỉ đến từ offline quỹ đạo.

Diffusion chính sách mở rộng ý tưởng chính sách tạo sinh sang phân phối hành động đa mode. Trong offline RL, cùng một state có thể có nhiều action hợp lệ do bộ dữ liệu chứa nhiều chiến lược khác nhau. Một Gaussian chính sách đơn mode có thể trung bình hóa các mode và sinh action không thuộc mode nào. Ngược lại, diffusion model có thể sinh action qua nhiều bước khử nhiễu và biểu diễn phân phối phức tạp hơn. Tuy nhiên, expressivity cao không tự bảo đảm policy improvement: khi diffusion chính sách được kết hợp với critic trong offline RL, các candidate ngoài support dữ liệu có thể nhận giá trị dự đoán sai. **Diffusion-DICE** tập trung vào chính tương tác giữa khả năng sinh đa mode và sai số ngoại suy của critic.

3.1.5. Nghiên cứu trường hợp: Diffusion-DICE

Diffusion-DICE là case study trung tâm cho diffusion chính sách trong offline RL [14]. Vấn đề kỹ thuật của phương pháp là tận dụng khả năng sinh action đa mode của diffusion model mà không để critic kéo chính sách ra khỏi support của dữ liệu. Trong diffusion chính sách, action sạch a_0 được sinh từ chuỗi khởi nhiễu $a_T, \dots, a_0$ có điều kiện trên state s . Mục tiêu không chỉ là bắt chước behavior chính sách trong bộ dữ liệu, mà là sinh action có giá trị cao theo reward hoặc hàm Q . Nút thắt mà công trình này xử lý là một điểm yếu cụ thể của diffusion chính sách trong offline RL: model đủ mạnh để sinh nhiều candidate actions, nhưng critic học từ dữ liệu offline có thể đánh giá sai các candidate nằm ngoài support. Do đó, kỹ thuật cốt lõi không chỉ là thêm guidance vào diffusion sampling, mà là kiểm soát cách guidance được dùng để tránh khai thác lỗi.

Hai hướng tiếp cận chính là guide-based và select-based. Guide-based methods học diffusion behavior chính sách rồi thêm guidance term để đẩy quá trình sampling về vùng có giá trị cao:

$$\nabla_{a_t} \log \pi_t(a_t | s) = \nabla_{a_t} \log \pi_t^D(a_t | s) + \nabla_{a_t} J_t(a_t, s). \quad (28)$$

Ở đây π_t^D là behavior diffusion chính sách, còn J_t là tín hiệu hướng dẫn học từ critic hoặc mục tiêu liên quan đến reward. Đối với nhóm select-only, một cách triển khai điển hình là sinh nhiều candidate actions từ behavior chính sách rồi tái lấy mẫu theo trọng số do critic cung cấp:

$$\Pr[a = a_0^j | s] = \frac{w(s, a_0^j)}{\sum_{i=1}^N w(s, a_0^i)}. \quad (29)$$


Phương trình (29) mô tả cơ chế resampling của nhóm baseline select-based, chẳng hạn **IDQL**; đây chưa phải bước Select cuối cùng của Diffusion-DICE [10]. Cả hai hướng đều phụ thuộc vào critic. Trong offline RL, critic chỉ được học từ bộ dữ liệu cố định; vì vậy critic có thể overestimate các action ngoài phân phối. Nếu sampling hoặc guidance đưa action ra khỏi vùng dữ liệu, chính sách có thể khai thác lỗi critic thay vì tìm action thật sự tốt. Hiện tượng này được gọi là khai thác lỗi.

Diffusion-DICE đề xuất paradigm guide-then-select. Bước guide dùng score của behavior chính sách cộng với guidance liên quan đến optimal distribution ratio để sinh candidate actions. Điểm cần trình bày cẩn thận là guidance term này không được tính bằng một closed-form đơn giản trong thực tế. Theo Diffusion-DICE, thành phần liên quan đến tỉ lệ mật độ thường intractable vì đòi hỏi các kỳ vọng điều kiện; phương pháp biến đổi bài toán thành mục tiêu có thể học in-sample. Sau đó, Diffusion-DICE thực hiện lựa chọn cứng trong tập K candidate actions được sinh từ optimal policy distribution $\pi^*(a | s)$ mà bước Guide xấp xỉ. Đặt $\mathcal{C}_K(s) = \{a_0^1, \dots, a_0^K\}$ với

$a_0^k \sim \pi^*(\cdot | s)$, bước Select được viết:


$$\pi(s) = a^* \triangleq \arg \max_{a \in \mathcal{C}_K(s)} Q^*(s, a). \quad (30)$$

Khác với phép resampling trong Phương trình (29), Phương trình (30) chọn candidate có giá trị Q lớn nhất, thay vì gán xác suất lựa chọn tỉ lệ với trọng số [14]. Nhờ vậy, critic vẫn được dùng để chọn action tốt hơn, nhưng quá trình lựa chọn được giữ gần vùng dữ liệu hơn.



Hình 5: Luồng guide-then-select trong Diffusion-DICE: Guide tạo candidate actions bằng behavior score và density-ratio signal, còn Select chỉ dùng hàm Q sau khi candidate đã được giữ gần support dữ liệu.

Toycaze 2D bandit cô lập chính xác vấn đề này. Bộ dữ liệu offline chỉ bao phủ một vùng hình khuyên (annular region). True reward cao ở outer circle, nhưng learned critic lại overestimate một số vùng inner circle do thiếu dữ liệu. Guide-only có thể bị kéo mạnh vào vùng critic overestimate, còn select-only bị giới hạn bởi chất lượng candidate. Diffusion-DICE giảm rủi ro bằng cách kết hợp hai bước: guide để tạo candidate hướng tới phân phối tối ưu, và select để chọn trong tập candidate theo hướng in-sample. **QGPO** và **IDQL** có thể được xem như các baseline đại diện cho hai cực guide-only và select-only, nhưng trọng tâm kỹ thuật của phần này là cơ chế guide-then-select của Diffusion-DICE [13, 10].



Hình 6: Toycaze 2D bandit của Diffusion-DICE: action trong bộ dữ liệu nằm trong vùng hình khuyên; true reward cao ở outer circle; learned reward overestimate inner circle; Diffusion-DICE giảm khai thác lỗi tốt hơn các hướng guide-only hoặc select-only. Nguồn hình: Figure 7 trong [7].

3.1.6. DDPO: xem quá trình khử nhiễu như một MDP

Nếu Diffusion-DICE dùng diffusion model để xây chính sách cho RL, **DDPO** đi theo chiều ngược lại: dùng RL để fine-tune diffusion model theo downstream reward [1]. Động lực của DDPO là nhiều mục tiêu quan trọng trong image generative models không được mô tả tốt bằng maximum likelihood. Aesthetic quality, prompt-image alignment hoặc compressibility là các tiêu chí được đánh giá ở mẫu cuối, không phải likelihood của từng bước huấn luyện diffusion. Do đó, fine-tuning bằng reward trở thành một bài toán RL tự nhiên. Ba thành phần kỹ thuật xác định **DDPO**: reward chỉ xuất hiện ở mẫu cuối, chuỗi khử nhiễu cung cấp một dãy decision steps, và gradient chính sách phân bổ tín hiệu reward cuối về từng transition khử nhiễu. Nhờ đó, DDPO trở thành một formulation RL đầy đủ cho quá trình sampling của diffusion model, thay vì chỉ là một thủ thuật tái trọng số các mẫu cuối có reward cao.

Trong diffusion sampling, một mẫu cuối x_0 được tạo ra từ chuỗi khử nhiễu:

$$x_T \rightarrow x_{T-1} \rightarrow \cdots \rightarrow x_0. \quad (31)$$

DDPO mô hình hóa chuỗi này như một finite-horizon MDP. Với prompt hoặc context c , state tại timestep t là noisy sample x_t . Action không nên hiểu cứng là predicted noise; cách mô tả đúng hơn là quyết định khử nhiễu, tức lấy mẫu x_{t-1} từ chính sách:

$$p_\theta(x_{t-1} \mid x_t, c). \quad (32)$$

Reward được chấm ở mẫu cuối, ký hiệu chung là $r(x_0, c)$; các ví dụ được DDPO khảo sát gồm compressibility, aesthetic quality và prompt-image alignment [1]. Theo bài báo DDPO, khi đó mục tiêu là kỳ vọng reward trên quỹ đạo khử nhiễu, và policy-gradient estimator có dạng:

$$\nabla_\theta J(\theta) = \mathbb{E} \left[r(x_0, c) \sum_{t=1}^T \nabla_\theta \log p_\theta(x_{t-1} \mid x_t, c) \right]. \quad (33)$$

Công thức này cho thấy reward cuối được gán credit cho toàn bộ chuỗi transition khử nhiễu. So với reward-weighted regression, DDPO giữ lại cấu trúc nhiều bước của quá trình sampling. RWR chỉ tăng likelihood của mẫu cuối có reward cao, trong khi DDPO cập nhật log-probability của từng transition $x_t \rightarrow x_{t-1}$. Theo bài báo DDPO, cách tiếp cận này hiệu quả hơn RWR trong các mục tiêu được khảo sát vì RWR gặp các vấn đề optimization và approximation trong diffusion setting [1].

Ở mức cụ thể hóa trong bài báo gốc, formulation này dẫn tới hai estimator. **DDPO-SF** áp dụng trực tiếp score-function estimator theo tinh thần REINFORCE trên các quỹ đạo khử nhiễu. **DDPO-IS** bổ sung importance sampling để tái sử dụng

quỹ đạo đã thu thập cho nhiều bước cập nhật hơn, đồng thời dùng clipping theo tinh thần PPO nhằm kiểm soát policy shift. Các chi tiết này thuộc phần triển khai của bài báo DDPO; trong tutorial, vai trò chính của DDPO là minh họa việc xem khử nhiễu như MDP và tối ưu diffusion model bằng gradient chính sách [1].

Trong formulation tổng quát của DDPO, chuỗi khử nhiễu được xem như một MDP và được tối ưu bằng gradient chính sách thay cho reward-weighted likelihood. Bài báo gốc cho thấy formulation này có thể fine-tune image generative models theo các downstream criteria như aesthetics, compressibility và prompt-image alignment hiệu quả hơn RWR trong các thiết lập được khảo sát; tuy nhiên, tối ưu một reward proxy không hoàn chỉnh vẫn có thể dẫn tới overoptimization hoặc reward hacking [1, 2].

Trong mạch lập luận chung, DDPO hoàn thiện quan hệ hai chiều giữa hai lĩnh vực. Diffusion-DICE đưa diffusion model vào RL để biểu diễn chính sách phức tạp. Ngược lại, DDPO đưa policy optimization vào diffusion model để điều chỉnh chính quá trình sampling. Cả hai công trình đều sử dụng cấu trúc nhiều bước của diffusion, nhưng tối ưu hai đối tượng khác nhau. Diffusion-DICE tìm action có giá trị cao trong offline RL. DDPO tối ưu chất lượng mẫu cuối theo downstream reward.

3.2. Quá trình tương tác như một mô hình tạo sinh

3.2.1. Cách chính sách và environment sinh dữ liệu


Góc nhìn thứ hai xem toàn bộ quá trình tương tác giữa chính sách và environment như một generative model. Một diffusion model tạo ảnh bằng nhiều bước khử nhiễu. Tương tự, một RL agent tạo observation tương lai bằng nhiều bước tương tác. Chính sách sinh action, environment sinh state kế tiếp, rồi quá trình lặp lại. Nếu s_0 là trạng thái ban đầu, quá trình

$$a_t \sim \pi(a_t \mid s_t), \quad s_{t+1} \sim p(s_{t+1} \mid s_t, a_t) \quad (34)$$

xác định một phân phối trên các state hoặc observation tương lai. Trong cách nhìn này, hệ agent–environment là một quá trình tạo sinh. Mẫu sinh ra không phải là ảnh, mà là trạng thái hoặc observation mà agent đạt được sau nhiều bước tương tác.


Ba động lực kỹ thuật làm cho cách mô hình hóa này hữu ích trong bối cảnh GenAI và RL. Động lực thứ nhất là RL cung cấp ngôn ngữ hình thức để mô tả hệ thống sinh có tương tác với con người, công cụ hoặc môi trường vật lý, kể cả khi một phần quá trình là hộp đen hoặc không khả vi. Động lực thứ hai là đặc tả tác vụ bằng scalar reward thường đòi hỏi reward engineering và reward shaping thủ công. Các thành phần trung gian có thể vô tình mã hóa trước cách giải thay vì chỉ mô tả kết quả

mong muốn. Động lực thứ ba là scalar reward tạo ra sự lệch pha với mô hình hóa tạo sinh thông thường, nơi supervision được cung cấp dưới dạng dữ liệu mẫu. Part II khảo sát khả năng đặc tả một lớp bài toán RL bằng desired observations hoặc goal data. Cách này chuyển một phần bài toán từ reward engineering sang khớp phân phối trên outcome [7].



Hình 7: So sánh generative models chuẩn với tương tác trong RL. Cả hai đều dùng nhiều bước tính toán hoặc tương tác để tạo mẫu. Nguồn hình: Figure 8 trong [7].

Cách nhìn này không yêu cầu toàn bộ chuỗi sinh phải được biểu diễn bởi một mạng khả vi: chính sách, environment, tool và human feedback chỉ cần cùng xác định một distribution trên outcome. Bài toán điều khiển sau đó có thể được phát biểu dưới dạng thay đổi chính sách để tăng likelihood của các outcome mong muốn, với đạt đích là trường hợp cụ thể được phân tích tiếp theo.



Hình 8: Quá trình tương tác tạo sinh: mỗi bước chính sách sinh action, environment sinh state kế tiếp, và toàn bộ vòng lặp tạo ra mẫu tương lai s_f .

3.2.2. Đạt đích và thước đo chiếm dụng

Đạt đích là thiết lập đơn giản nhất cho quan điểm xem quá trình tương tác như một mô hình tạo sinh. Thay vì reward engineering thủ công nhiều thành phần, task được mô tả bằng một observation mong muốn g . Đạt đích trước hết có thể được hiểu bằng trực giác indicator trong finite-state setting: agent nhận tín hiệu dương khi đạt goal và nhận tín hiệu bằng không ở các trạng thái khác. Để có formulation áp dụng

được cho cả observation rời rạc lẫn liên tục, mục tiêu chính được viết qua xác suất transition tới goal:

$$\max_{\pi} (1 - \gamma) \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t p(s_{t+1} = g \mid s_t, a_t) \right]. \quad (35)$$

Hệ số $(1 - \gamma)$ chuẩn hóa tổng chiết khấu thành một phân phối. Mục tiêu này tương đương một bài toán RL chuẩn với reward được định nghĩa từ xác suất đạt observation mong muốn:


$$r_g(s, a) = (1 - \gamma) p(s' = g \mid s, a). \quad (36)$$

Reward ở đây không phải reward thủ công theo nhiều rule, mà được định nghĩa từ xác suất đạt observation mong muốn. Điều này chuyển reward engineering sang bài toán likelihood của outcome.

Discounted state thước đo chiếm dụng mô tả phân phối state tương lai do chính sách sinh ra:

$$p^{\pi}(s_f) \triangleq (1 - \gamma) \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t p(s_{t+1} = s_f \mid s_t, a_t) \right]. \quad (37)$$

Nếu quá trình tương tác là một generative model, $p^{\pi}(s_f)$ chính là phân phối mẫu mà model tạo ra. Đạt đích khi đó trở thành bài toán điều chỉnh chính sách sao cho phân phối p^{π} đặt xác suất cao lên goal hoặc goal distribution.



Hình 9: Đạt đích thay nhiều thành phần reward thủ công bằng một desired observation g ; mục tiêu kỹ thuật là tăng xác suất $p^{\pi}(s_f = g)$.

Hạn chế của đạt đích là không phải mọi tác vụ đều có thể được đặc tả bằng một trạng thái đích đơn lẻ. Chẳng hạn, trạng thái “căn phòng sạch” có thể tương ứng với nhiều cấu hình quan sát hợp lệ, trong khi tiêu chí “chuyến bay êm” phụ thuộc vào các ràng buộc được duy trì trên toàn quỹ đạo. Về mặt kỹ thuật, các ví dụ này đại diện cho tác vụ có nhiều outcome tương đương hoặc có constraints trên quỹ đạo, do đó không thể quy về một goal observation duy nhất. Do đó, đạt đích chỉ là một trường hợp đặc biệt của bài toán điều khiển phân phối outcome; các tác vụ tổng quát hơn đòi hỏi formulation trên distribution quỹ đạo hoặc reward function đầy đủ.

3.2.3. Goal-conditioned sao chép hành vi

Goal-Conditioned Behavioral Cloning (GCBC) khai thác cấu trúc quỹ đạo để học chính sách hướng goal từ dữ liệu. Trong nhóm công trình về tương tác như một mô hình tạo sinh, GCBC đóng vai trò baseline theo kiểu học có giám sát. Nó tận dụng quỹ đạo có sẵn bằng cách dùng observation tương lai làm goal label. Sau đó, Học tăng cường song nguyên và DICE mở rộng ý tưởng này lên mức occupancy-level khớp phân phối. Từ một quỹ đạo trong bộ dữ liệu, ta chọn một future state s_f làm goal, rồi huấn luyện chính sách sinh action hiện tại có điều kiện trên goal:

$$\max_{\theta} \mathbb{E}_{\tau \sim \mathcal{D}} [\mathbb{E}_{(s,a,s_f) \sim \tau} [\log \pi_{\theta}(a \mid s, g = s_f)]] . \quad (38)$$

Diễn giải Bayes. Phương trình (38) có hình thức của sao chép hành vi với biến điều kiện goal, nhưng Bayes rule cho thấy mục tiêu còn mã hóa xác suất đạt future state. Action được ưu tiên không chỉ vì nó xuất hiện trong dữ liệu, mà vì trong quỹ đạo gốc nó nằm trên đường dẫn đến future state được chọn làm goal. Một cách viết bỏ qua các hằng số không phụ thuộc action là:

$$\mathbb{E}_{a \sim \pi_{\theta}(a|s,g)} [\log p(s_f = g \mid s, a) + \log \beta(a \mid s)] , \quad (39)$$

trong đó $\beta(a \mid s)$ là behavior chính sách, còn $p(s_f = g \mid s, a)$ là xác suất đạt future goal khi bắt đầu từ (s, a) và tiếp tục theo chính sách đang xét. Hạng tử đầu khuyến khích action làm tăng khả năng đạt goal. Hạng tử thứ hai regularize action về vùng hành vi trong bộ dữ liệu. GCBC do đó kết hợp tín hiệu đạt đích với regularization về behavior support, thay vì chỉ sao chép marginal action distribution.

Diễn giải bằng mặt nạ (masking). Diễn giải trọng tâm thứ hai xem GCBC như một bài toán masked sequence modeling trên quỹ đạo. Trong language modeling, masking che một phần token rồi học dự đoán token bị che. Trong modeling quỹ đạo, có thể che action hoặc state rồi yêu cầu mô hình khôi phục phần thiếu. Với GCBC, state hiện tại và goal tương lai đóng vai trò context, còn action là phần cần dự đoán. Nếu mask action, mô hình hoạt động như chính sách. Nếu mask future state, cùng kiến trúc hoạt động như mô hình thế giới. Sự thay đổi vai trò được quyết định bởi biến nào được quan sát và biến nào phải sinh, chứ không nhất thiết bởi một kiến trúc riêng cho từng chức năng.

GCBC cho thấy một cách tận dụng offline quỹ đạo bằng học có giám sát. Tuy nhiên, chính sách học được vẫn bị ràng buộc mạnh bởi behavior support và các future states đã xuất hiện trong dữ liệu. Để phân tích các phương pháp vượt ra ngoài việc clone trực tiếp hành vi, cần chuyển từ likelihood của action sang phân phối occupancy

mà chính sách tạo ra. Ở mức on-policy, f-divergence gradient cung cấp một cầu nối tự nhiên giữa khớp phân phối goal và gradient chính sách. Trong offline setting, yêu cầu học từ bộ dữ liệu cố định dẫn tới các formulation dual và DICE được trình bày tiếp theo [7].

3.2.4. Học tăng cường song nguyên và DICE

Đạt đích yêu cầu ước lượng xác suất đạt goal, nhưng density estimation trực tiếp trong không gian observation cao chiều thường khó. **Học tăng cường song nguyên** giải quyết vấn đề này bằng cách làm việc với thước đo chiếm dụng và khớp phân phối. Thay vì tối ưu trực tiếp trên chính sách, ta xét state-action occupancy $d^\pi(s, a)$ do chính sách tạo ra. Một mục tiêu có regularization có dạng:

$$\max_{\pi} \mathbb{E}_{(s,a) \sim d^\pi} [r(s, a)] - \alpha D_f(d^\pi(s, a) \| d^O(s, a)), \quad (40)$$

trong đó d^O là phân phối tham chiếu và D_f là f -divergence. Occupancy distribution không thể tùy ý. Nó phải thỏa các Bellman-flow constraints do dynamics quy định. Một dạng ràng buộc Bellman-flow tương ứng với primal-Q trong notes là:

$$d(s, a) = (1 - \gamma)d_0(s)\pi(a | s) + \gamma \sum_{s', a'} d(s', a')p(s | s', a')\pi(a | s), \quad \forall s, a. \quad (41)$$

Ràng buộc này đảm bảo $d(s, a)$ là một thước đo chiếm dụng hợp lệ, tức nó có thể được sinh ra bởi một chính sách trong MDP thay vì là một phân phối tùy ý trên state-action pairs. Bằng Lagrangian duality và convex conjugate, các ràng buộc flow có thể được chuyển thành mục tiêu theo các biến dual như $Q(s, a)$ hoặc $V(s)$. Ví dụ, một dạng dual-V được notes trình bày là:

$$\min_V (1 - \gamma)\mathbb{E}_{s \sim d_0} [V(s)] + \alpha \mathbb{E}_{(s,a) \sim d^O} \left[f_p^* \left(\frac{\mathcal{TV}(s, a) - V(s)}{\alpha} \right) \right], \quad (42)$$

trong đó $\mathcal{TV}(s, a)$ là Bellman target của V và f_p^* là biến thể convex conjugate dùng để xử lý ràng buộc không âm của occupancy. Ý nghĩa kỹ thuật là bài toán khớp phân phối có thể được học bằng loss trên dữ liệu logged, thay vì yêu cầu tương tác on-policy liên tục.

DICE methods là họ phương pháp tiêu biểu cho ý tưởng này. Trong offline setting, DICE xét mục tiêu:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{(s,a) \sim d^\pi} [r(s, a)] - \alpha D_f(d^\pi \| d^D), \quad (43)$$

trong đó d^D là distribution của dữ liệu offline, tức phân phối state-action pairs đã được

ghi nhận trước khi học chính sách mới. Bài toán trực tiếp khó vì d^π phụ thuộc vào chính sách và dynamics. Sau biến đổi dual, mục tiêu có thể được ước lượng từ các mẫu (s, a, s') trong dataset. Tính in-sample của DICE nằm ở việc các loss dual được đánh giá trên transition đã ghi nhận, qua đó tránh yêu cầu truy vấn giá trị của toàn bộ không gian action ngoài support dữ liệu. Trong triển khai thực tế, notes trình bày một dạng semi-gradient dùng $Q(s, a)$ để xấp xỉ Bellman target và $V(s)$ để biểu diễn biến dual theo state:

$$\begin{aligned} \min_V \quad & \mathbb{E}_{(s,a) \sim d^D} \left[(1 - \gamma)V(s) + \alpha f^* \left(\frac{Q(s, a) - V(s)}{\alpha} \right) \right], \\ \min_Q \quad & \mathbb{E}_{(s,a,s') \sim d^D} [r(s, a) + \gamma V(s') - Q(s, a)]^2. \end{aligned} \quad (44)$$

Hai loss này chỉ cần các transition đã ghi trong dữ liệu offline, nên phù hợp với mục tiêu in-sample của DICE methods.

Một đại lượng trung tâm là stationary distribution ratio:

$$w^*(s, a) := \frac{d^*(s, a)}{d^D(s, a)}. \quad (45)$$

Tỉ số này cho biết state-action pair trong bộ dữ liệu nên được nhấn mạnh hơn hay ít hơn để tiến đến occupancy tối ưu. Từ góc nhìn tổng hợp của nhóm, tỉ lệ mật độ ở đây cũng cung cấp một cách diễn giải cho guidance trong Diffusion-DICE: cả hai đều mô tả sự dịch chuyển từ behavior distribution về phía optimal distribution, trong khi ràng buộc in-sample hạn chế khai thác lỗi. Liên hệ này là phép đối chiếu giữa hai phần của tutorial, không phải một đồng nhất thức được lecture notes phát biểu trực tiếp [7, 14].

3.2.5. f -Policy Gradients và state-MaxEnt RL

Dual formulation cho biết cách biểu diễn bài toán bằng thước đo chiếm dụng và tỉ lệ mật độ. Từ formulation này, câu hỏi trực tiếp hơn là: nếu goal được mô tả bởi một phân phối trạng thái đích $p_g(s)$, chính sách cần được cập nhật như thế nào để phân phối trạng thái mà agent tạo ra tiến gần tới phân phối này? Gọi $p_\theta(s)$ là discounted state distribution sinh bởi chính sách π_θ . Bài toán khớp phân phối được viết dưới dạng:

$$J(\theta) = D_f(p_\theta(s) \| p_g(s)). \quad (46)$$

Mục tiêu này thay reward engineering theo từng trạng thái bằng yêu cầu khớp phân phối giữa outcome của agent và phân phối goal.

Định lý 3.1 trong lecture notes cung cấp gradient của Phương trình (46):

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \left[\left(\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{t=1}^T f' \left(\frac{p_{\theta}(s_t)}{p_g(s_t)} \right) \right) \right]. \quad (47)$$

Thừa số thứ nhất là tổng hàm điểm số của chính sách trên quỹ đạo. Thừa số thứ hai cung cấp dense weights từ tỉ lệ mật độ giữa state distribution hiện tại và goal distribution. Do bài toán tối thiểu hóa $J(\theta)$, hướng cập nhật có cấu trúc giống gradient chính sách với tín hiệu hiệu dụng $-f'(p_{\theta}(s_t)/p_g(s_t))$, thay vì reward thừa được thiết kế thủ công. Tuy nhiên, lecture notes lưu ý rằng không thể đồng nhất phép cập nhật này với việc cực đại hóa một surrogate return thông thường, bởi tỉ lệ mật độ và trọng số tương ứng cũng phụ thuộc vào θ . Estimator trên còn mang tính on-policy, nên đòi hỏi quỹ đạo từ chính sách hiện tại và có thể kém hiệu quả dữ liệu [7].

Trường hợp cụ thể với forward KL minh họa rõ hơn mối liên hệ giữa khớp phân phối và exploration. Khi D_f là $D_{\text{KL}}(p_{\theta} || p_g)$, việc cực tiểu hóa divergence tương đương với:

$$\max_{\pi_{\theta}} \mathbb{E}_{s \sim p_{\theta}} [\log p_g(s)] + \mathcal{H}(p_{\theta}(s)). \quad (48)$$

Hạng tử thứ nhất đưa state distribution về các vùng có xác suất cao dưới goal distribution; hạng tử thứ hai cực đại hóa entropy của chính state occupancy. Đây là điểm khác với MaxEnt RL thông dụng như soft Q-learning hoặc SAC, vốn regularize entropy của action chính sách. Một chính sách có action entropy cao vẫn có thể tạo ra state distribution hẹp nếu dynamics khiến nhiều action dẫn tới cùng một vùng trạng thái. Ngược lại, **state-MaxEnt RL** tác động trực tiếp lên độ phủ của các trạng thái được ghé thăm. Đặc biệt, nếu p_g là phân phối đều trên state space, term $\log p_g(s)$ trở thành hằng số và mục tiêu còn lại là cực đại hóa $\mathcal{H}(p_{\theta}(s))$, tức khuyến khích agent khám phá rộng trong môi trường. Diễn giải này là nội dung được nhấn mạnh trong phần f-Policy Gradients và state-MaxEnt RL của slide tutorial [7]. Minh họa GridWorld trong slide tutorial cho thấy state-MaxEnt hướng tới độ phủ trạng thái rộng hơn so với các biến thể chỉ tập trung vào một đường đi hoặc chỉ tăng entropy ở mức action.

3.2.6. Offline học tăng cường có điều kiện đích

Trong offline học tăng cường có điều kiện đích, goal-transition distribution $q(s, a, g)$ được dùng để mô tả những transition dẫn tới goal. Với một stochastic MDP,

notes định nghĩa phân phối này theo dạng:

$$q(s, a, g) \propto q_{\text{train}}(g) \mathbb{E}_{s' \sim p(\cdot | s, a)} [\mathbf{1}\{\phi(s') = g\}]. \quad (49)$$

Bài toán được viết dưới dạng occupancy matching:

$$D_f(d^{\pi_g}(s, a, g) \| q(s, a, g)). \quad (50)$$

Vì q có thể không đạt được chính xác bởi bất kỳ chính sách nào và dữ liệu offline có support hữu hạn, dual formulation với divergence phù hợp được dùng để thu được mục tiêu ổn định hơn. Dạng dual thu được một mục tiêu contrastive có Bellman regularization. Mục tiêu này có ba vai trò song song. Thứ nhất, nó tăng score cho các transition phù hợp với goal-transition distribution. Thứ hai, nó giảm score cho các transition dưới chính sách hiện tại. Thứ ba, nó ràng buộc score theo Bellman structure. Viết gọn theo notation của notes, mục tiêu này có dạng:

$$\begin{aligned} \max_{\pi_g} \min_S \quad & \beta(1 - \gamma) \mathbb{E}_{d_0, \pi_g} [S(s, a, g)] + \beta \gamma \mathbb{E}_{q, p, \pi_g} [S(s', a', g)] \\ & - \beta \mathbb{E}_q [S(s, a, g)] + \frac{1}{4} \mathbb{E}_{\text{Mix}_{\beta}(q, \rho)} [\gamma S(s', a', g) - S(s, a, g)]^2. \end{aligned} \quad (51)$$

Ở đây $\mathbb{E}_{d_0, \pi_g}$ rút gọn cho kỳ vọng trên $(s, g) \sim d_0$ và $a \sim \pi_g(\cdot | s, g)$. Còn $\mathbb{E}_{q, p, \pi_g}$ rút gọn cho $(s, a, g) \sim q$, $s' \sim p(\cdot | s, a)$ và $a' \sim \pi_g(\cdot | s', g)$. Ba nhóm hạng tử đầu tương ứng với giảm score dưới chính sách hiện tại và tăng score ở proposed goal-transition distribution, còn hạng tử cuối là Bellman regularization.

Cần phân biệt rõ S -function trong formulation này với reward thật hoặc likelihood thật. S là một score được học bằng Bellman-regularized contrastive learning. Vai trò của nó là cung cấp tín hiệu học cho occupancy matching trong offline học tăng cường có điều kiện đích, không phải thay thế trực tiếp cho reward được gán nhãn. Điểm này quan trọng vì nó ngăn cách lập luận ở đây khỏi một diễn giải quá đơn giản rằng mọi bài toán RL chỉ cần chuyển thành density estimation. Trong thực tế, các ràng buộc dynamics, support của dữ liệu offline và độ ổn định tối ưu vẫn quyết định chất lượng chính sách học được.

Đánh giá kỹ thuật và câu hỏi mở. Các phương pháp trong Part I và Part II giúp nhìn RL như một bài toán kiểm soát phân phối. Tuy nhiên, chúng không làm bài toán trở nên đơn giản hoàn toàn.


Ở Part I, mô hình thế giới giúp mô phỏng môi trường và diffusion chính sách giúp sinh action đa dạng. Điểm yếu là chính sách vẫn có thể khai thác lỗi ngoại suy của mô hình thế giới hoặc critic. Diffusion-DICE giảm rủi ro này bằng cách ưu tiên action nằm

trong miền dữ liệu, nhưng chất lượng cuối cùng vẫn phụ thuộc vào critic [14]. DDPO cũng có giới hạn tương tự. Nó tối ưu trực tiếp reward proxy. Nếu reward proxy chưa phản ánh đúng ý định thật, model có thể tối ưu sai mục tiêu [1].

Ở Part II, đạt đích thay việc tự viết scalar reward bằng việc cung cấp goal. Cách làm này dễ dùng hơn, nhưng không miễn phí. Người thiết kế vẫn phải chọn goal representation và goal distribution. Nếu dữ liệu goal bị lệch, chính sách học được cũng sẽ lệch. GCBC tận dụng dữ liệu quỹ đạo có sẵn, nhưng nó chủ yếu học lại những hành vi nằm trong behavior support. Vì vậy, GCBC không tự bảo đảm khả năng tạo ra những đường đi mới chưa từng xuất hiện trong dữ liệu offline.

Học tăng cường song nguyên và DICE tiến thêm một bước bằng cách so khớp thước đo chiếm dụng thay vì chỉ bắt chước từng action. Tuy nhiên, chúng cần ước lượng tỉ lệ mật độ ổn định. Ước lượng này phụ thuộc vào độ phủ dữ liệu, lựa chọn f -divergence và sai số của biến dual. Với f -Policy Gradients, estimator trong lecture notes là on-policy. Nghĩa là tín hiệu khớp phân phối dày hơn, nhưng phải trả giá bằng việc thu thập quỹ đạo mới.

Từ các hạn chế trên, có ba hướng mở hợp lý. Thứ nhất là kết hợp chính sách tạo sinh đa mode với ước lượng uncertainty, để biết khi nào action hoặc quỹ đạo nằm ngoài miền dữ liệu đáng tin cậy. Thứ hai là nối offline learning với online data collection có chủ đích, nhằm mở rộng support ở những vùng mà critic hoặc tỉ lệ mật độ còn không chắc chắn. Thứ ba là xử lý các tác vụ không thể mô tả bằng một goal observation tĩnh. Những tác vụ này cần mô hình hóa phân phối trên quỹ đạo hoặc outcome có cấu trúc, thay vì chỉ thay reward bằng một ảnh đích [7]. Vì vậy, thông điệp chính không phải là thay RL bằng density estimation. Thông điệp chính là dùng score, likelihood hoặc tỉ lệ mật độ để kiểm soát tốt hơn phân phối mà chính sách tạo ra.



Hình 10: Tổng hợp hai mức phân tích của tutorial. Phần I đặt generative models vào hệ RL. Phần II xem quá trình tương tác của agent như một mô hình tạo sinh tạo ra occupancy, goal và outcome distribution.

3.3. Học Likelihoods

Phần II đã giới thiệu cách nhìn nhận tương tác như một quá trình generative và sử dụng góc nhìn này cho bài toán đạt đích. Phần III mở rộng thêm: nếu tương tác là một generative model, thì chúng ta có thể **ước lượng likelihood** của các kết quả quan sát được không? Câu trả lời là có, và điều này cho phép giải quyết các bài toán RL tổng quát hơn nhiều so với đạt đích đơn thuần.

3.3.1. Successor Measure

Định nghĩa Successor Measure **Thước đo kế tiếp** (hay thước đo chiếm dụng trạng thái chiết khấu) $p^\pi(s_f)$ được định nghĩa là xác suất agent đến được trạng thái s_f tại một thời điểm nào đó trong tương lai:

$$p^\pi(s_f) \triangleq (1 - \gamma) \mathbb{E}_\pi \left[\sum_t \gamma^t p(s_{t+1} = s_f \mid s_t, a_t) \right] \quad (52)$$

Đây chính xác là likelihood của việc “sampling” trạng thái s_f từ generative model được định nghĩa bởi RL agent. Phiên bản có điều kiện $p^\pi(s_f \mid s, a)$ cho biết xác suất đến s_f khi bắt đầu từ trạng thái s và thực hiện hành động a .



Hình 11: Thước đo kế tiếp (thước đo chiếm dụng trạng thái chiết khấu) là phân phối các trạng thái tương lai mà agent có thể đến được. Phần III giới thiệu các kỹ thuật ước lượng phân phối này và sử dụng nó cho RL. Nguồn: [7].

3.3.2. Ước lượng Mật độ Trực tiếp

Phương pháp Trực tiếp và Hạn chế Một cách tiếp cận trực quan để ước lượng $p^\pi(s_f)$ là sử dụng các mô hình generative hiện đại như **flow-matching**, **GANs**, hoặc **normalizing flows** để học phân phối của các trạng thái mà agent thực sự ghé thăm. Sau khi có mô hình mật độ, bài toán đạt đích được giải quyết bằng cách tối đa hóa xác suất đến trạng thái mục tiêu g :

$$\arg \max_a p^\pi(s_f = g \mid s, a) \quad (53)$$

Tuy nhiên, cách tiếp cận này gặp phải một khó khăn cơ bản: **ước lượng mật độ**

trong không gian chiều cao là cực kỳ khó khăn. Với không gian trạng thái liên tục nhiều chiều (như hình ảnh hoặc trạng thái robot), các phương pháp density estimation trực tiếp bị ảnh hưởng bởi curse of dimensionality và đòi hỏi lượng dữ liệu rất lớn để hội tụ.

Nhận thức này dẫn đến hướng tiếp cận hiệu quả hơn: thay vì ước lượng $p^\pi(s_f)$ trực tiếp, ta chỉ cần ước lượng **tỉ lệ xác suất tương đối** (relative likelihood) – một bài toán dễ hơn và có thể được quy về bài toán phân loại nhị phân [7].

3.3.3. Học Tương phản Thời gian


Ước lượng Relative Likelihood Việc ước lượng trực tiếp $p^\pi(s_f)$ trong không gian chiều cao rất khó khăn. Một hướng tiếp cận hiệu quả hơn là ước lượng **tỉ lệ xác suất tương đối**:

$$\frac{p^\pi(s_f | s, a)}{p(s_f)} \quad (54)$$

Tỉ lệ này có thể được ước lượng như một bài toán phân loại: phân biệt các cặp (s, a, s_f) mà s_f thực sự là trạng thái tương lai của (s, a) (positive examples) với các cặp ngẫu nhiên (negative examples). Classifier $f_\theta(s, a, s_f)$ được huấn luyện với loss:

$$\min_{\theta} -\mathbb{E}_{p^\pi(s_f|s,a)p(s,a)} \left[\log \frac{1}{1 + \frac{1}{f_\theta(s,a,s_f)}} \right] - \mathbb{E}_{p(s_f)p(s,a)} \left[\log \frac{1}{1 + f_\theta(s,a,s_f)} \right] \quad (55)$$

Tại điểm tối ưu: $f_\theta(s, a, s_f) = \frac{p^\pi(s_f|s,a)}{p(s_f)}$. Đây chính là **học tương phản thời gian** [7].



Hình 12: Ước lượng relative likelihood qua temporal contrastive learning. Classifier học phân biệt cặp (s, a, s_f) thật (future state thực sự) với cặp ngẫu nhiên, từ đó ước lượng tỉ lệ xác suất $p^\pi(s_f | s, a)/p(s_f)$. Nguồn: [7].

Temporal Difference Methods: Mở rộng sang Off-policy Các phương pháp Monte Carlo ở trên ước lượng thước đo kế tiếp bằng cách quan sát trực tiếp nơi chính sách đến. Tuy nhiên, chúng không trả lời được câu hỏi: *nếu chính sách thay đổi, agent sẽ visit những state nào mới?* Temporal difference (TD) methods giải quyết vấn đề này bằng cách “ghép nối” dữ liệu từ các experience khác nhau thông qua Bellman flow constraint [7]:

$$p^\pi(s_f | s_0, a_0) = p(s_1 = s_f | s_0, a_0) + \gamma \mathbb{E}_{p(s_1 | s_0, a_0) \pi(a_1 | s_1)} [p^\pi(s_f | s_1, a_1)] \quad (56)$$

Identity này cho phép viết lại contrastive loss dưới dạng chỉ phụ thuộc vào các transition (s, a, s') và chính sách hiện tại – không cần sample future states trực tiếp. Đây là nền tảng của một số phương pháp quan trọng:

Bảng 6: So sánh các phương pháp ước lượng thước đo kế tiếp.

Phương pháp	Loại	Đặc điểm
Monte Carlo contrastive C-learning	On-policy	Đơn giản, cần nhiều mẫu
Forward-Backward (FB)	TD, off-policy	Recursive classification
TD InfoNCE	TD, off-policy	Linear parametrization
	TD, off-policy	Log-linear, InfoNCE loss

Nguồn: [7].

C-learning [7] reformulate đạt đích như bài toán phân loại đệ quy: thay vì học trực tiếp $p^\pi(s_f | s, a)$, học classifier phân biệt các cặp (s, s_f) có quan hệ nhân quả với các cặp ngẫu nhiên, kết hợp TD updates để propagate thông tin qua thời gian.

Forward-Backward representation sử dụng linear parametrization $f_\theta(s, a, s_f) = F_\theta(s, a)^\top B_\theta(s_f)$, cho phép tính hàm Q cho bất kỳ reward function nào chỉ bằng một tích vô hướng sau khi đã học representation – nền tảng cho học tăng cường không cần huấn luyện lại.

TD InfoNCE sử dụng log-linear parametrization $f_\theta(s, a, s_f) = e^{F_\theta(s, a)^\top B_\theta(s_f)}$ kết hợp với InfoNCE loss, cho phép scaling tốt hơn và có liên hệ chặt chẽ với học tương phản thời gian trong computer vision.

Biểu diễn Tham số hóa Thay vì coi f_θ như một black-box, có thể tham số hóa dưới dạng tích vô hướng của hai biểu diễn:

$$f_\theta(s, a, s_f) = e^{F_\theta(s, a)^\top B_\theta(s_f)} \quad (57)$$

trong đó $F_\theta(s, a)$ là *forward representation* của cặp state-action và $B_\theta(s_f)$ là *backward representation* của trạng thái đích. Biểu diễn này có nhiều tính chất thú vị:

- **Scaling:** mạng lớn hơn cho kết quả tốt hơn đáng kể, lên đến mạng 1000 lớp [7].
- **Emergent exploration:** chiến lược khám phá tự xuất hiện trong quá trình huấn luyện.
- **Triangle inequality:** biểu diễn học được thỏa mãn bất đẳng thức tam giác, cho phép lập kế hoạch qua nội suy.
- **Tổng quát hóa chân trời:** huấn luyện trên task horizon ngắn, giải được task horizon dài.

hàm Q cũng có thể được ước lượng từ các biểu diễn này:

$$Q(s, a) \approx \frac{1}{k} \sum_{s_f, r} f_\theta(s, a, s_f) \cdot r(s_f) \quad (58)$$

Điều này cho thấy một reward function bất kỳ có thể được biểu diễn như một vector z duy nhất – nền tảng cho học tăng cường không cần huấn luyện lại.

3.3.4. Học Tăng cường Tổng quát từ Tỷ lệ Mật độ

Từ Đạt đích đến RL Tổng quát Các phương pháp ở phần trước cho phép ước lượng xác suất agent đến một trạng thái đích s_f cụ thể. Tuy nhiên, nhiều bài toán thực tế không thể mô tả bằng một goal state duy nhất – chúng ta có thể muốn tối đa hóa reward tổng quát, hoặc có nhiều trạng thái tốt với mức độ khác nhau [7].

Điểm then chốt là: các tỉ lệ mật độ $f_\theta(s, a, s_f)$ đã học có thể được tái sử dụng trực tiếp để giải quyết bài toán RL tổng quát. Cho một tập trạng thái có nhãn reward $\{(s_f, r(s_f))\}$, hàm Q được ước lượng bằng:

$$Q(s, a) = \mathbb{E}_{p(s_f|s,a)}[r(s_f)] = \mathbb{E}_{p(s_f)} \left[\frac{p(s_f|s, a)}{p(s_f)} r(s_f) \right] \approx \frac{1}{k} \sum_{s_f, r} f_\theta(s, a, s_f) \cdot r(s_f) \quad (59)$$

Biểu thức này có dạng **kernel smoothing**: thay vì kernel cố định, ta học biểu diễn sao cho kernel có ý nghĩa về mặt xác suất. Điều này cho phép giải quyết bất kỳ reward function nào chỉ với một lần học representation – không cần train lại từ đầu.

Linear Parametrization Với tham số hóa tuyến tính:

$$f_\theta(s, a, s_f) = F_\theta(s, a)^\top B_\theta(s_f) \quad (60)$$

hàm Q trở thành hàm tuyến tính của representation:

$$Q(s, a) \approx \frac{1}{k} \sum_{s_f, r} F_\theta(s, a)^\top B_\theta(s_f) \cdot r = F_\theta(s, a)^\top \underbrace{\left(\frac{1}{k} \sum_{s_f, r} B_\theta(s_f) \cdot r \right)}_z \quad (61)$$

Ký hiệu $z = \frac{1}{k} \sum_{s_f, r} B_\theta(s_f) \cdot r$ là vector đặc trưng của reward function. Tính chất quan trọng: **mỗi reward function được biểu diễn bởi một vector z duy nhất**, và hàm Q chỉ là tích vô hướng $F_\theta(s, a)^\top z$. Điều này cho phép zero-shot generalization: khi có reward function mới, chỉ cần tính z mới mà không cần cập nhật F_θ [7].

Log-linear Parametrization Với tham số hóa log-linear:

$$f_\theta(s, a, s_f) = e^{F_\theta(s, a)^\top B_\theta(s_f)} \quad (62)$$

Parametrization này phù hợp tự nhiên với các contrastive loss dạng InfoNCE [7]. So với linear parametrization, log-linear có một số tính chất nổi bật:

- **Scaling mạnh hơn**: mạng sâu đến 1000 lớp vẫn cải thiện đáng kể, điều hiếm thấy trong RL thông thường.
- **Triangle inequality**: biểu diễn học được thỏa mãn bất đẳng thức tam giác trong không gian metric, cho phép lập kế hoạch bằng nội suy giữa các biểu diễn.

- **Tổng quát hóa chân trời:** huấn luyện trên horizon ngắn, suy ra được chính sách cho horizon dài hơn.
- **Emergent exploration:** chiến lược khám phá tự xuất hiện khi huấn luyện với một goal duy nhất.

3.3.5. Thước đo Kế tiếp Nguyên mẫu (PSM)

Tập hợp Affine của Successor Measures Các biểu diễn Forward-Backward đã cho phép ước lượng hàm Q cho bất kỳ reward function nào thông qua một tích vô hướng. Tuy nhiên, có thể tổng quát hóa thêm: tập hợp tất cả các successor measures có thể học được tạo thành một **affine set** và được mô hình hóa qua:

$$M^\pi(s, a, s_f) = \Phi(s, a, s_f)^\top w^\pi + b(s, a, s_f) \quad (63)$$

trong đó $\Phi(s, a, s_f)$ là một **basis set** chung cho tất cả các chính sách, và w^π là vector trọng số phụ thuộc vào chính sách cụ thể. **Proto-Successor Measure (PSM)** là ý tưởng học chính các basis functions Φ này từ dữ liệu transitions offline; khi đó, với bất kỳ chính sách π mới nào, chỉ cần tìm w^π phù hợp mà không cần học lại biểu diễn từ đầu.

Liên hệ với RLZero và Học tăng cường không cần huấn luyện lại PSM có một tính chất quan trọng: khi được huấn luyện trên dữ liệu offline từ nhiều chính sách khác nhau, PSM học được một **biểu diễn phổ quát của hành vi** – không phụ thuộc vào chính sách hay reward function cụ thể nào. Đây là **nền tảng kỹ thuật** trực tiếp cho RLZero [19]:

1. PSM cung cấp backward representation $\phi(s)$ đã được pretrain trên dữ liệu offline của môi trường.
2. Khi nhận expert trajectory $\{s_1, \dots, s_T\}$ (từ ngôn ngữ hay video), RLZero chỉ cần tính trung bình: $z_{\text{init}} = \mathbb{E}_{\rho^E}[\phi(s)]$.
3. Điểm z_{init} tra vào PSM cho ra chính sách tối ưu tức thì – không cần gradient update, không cần interaction mới với môi trường.

Nói cách khác, PSM cung cấp “từ điển hành vi” mà RLZero tra cứu để biến ngôn ngữ tự nhiên thành chính sách [7].


3.3.6. RLZero: Học Tăng cường Không cần Huấn luyện lại từ Ngôn ngữ Tự nhiên

Vấn đề và Động lực Dù các phương pháp học tăng cường không cần huấn luyện lại đã cho phép suy ra chính sách tối ưu cho bất kỳ reward function nào, việc *chỉ định* reward function vẫn là thách thức. Ngôn ngữ tự nhiên là kênh giao tiếp trực quan nhất giữa con người và AI, nhưng các phương pháp trước đây yêu cầu:

- Dữ liệu có nhãn liên kết ngôn ngữ với hành vi trong domain cụ thể.
- Huấn luyện thêm khi nhận lệnh mới.

RLZero [19] giải quyết cả hai vấn đề trên, cho phép suy ra chính sách trực tiếp từ câu lệnh ngôn ngữ **mà không cần bất kỳ supervision trong domain nào**.

Framework: Imagine – Project – Imitate RLZero gồm ba bước chính, minh họa trong Hình 13:



Hình 13: Framework của RLZero gồm 3 bước: Imagine (tưởng tượng video từ ngôn ngữ), Project (chiếu về không gian quan sát của agent), Imitate (suy ra chính sách zero-shot). Nguồn: [19].

Bước 1 – Imagine (Tưởng tượng):

Cho câu lệnh ngôn ngữ ℓ (ví dụ: “Do a lunge”), Video Foundation Model VM sinh ra chuỗi frame video $\{i_1, i_2, \dots, i_T\}$ thể hiện hành vi tương ứng:

$$VM(f_i(\ell)) = (i_1, i_2, \dots, i_T)$$

Video model được huấn luyện hoàn toàn không có nhãn (unsupervised) trên dữ liệu tương tác offline của agent, sử dụng InternVideo2 làm video-language encoder và kiến trúc GRU đơn giản cho việc sinh video.

Bước 2 – Project (Chiếu):

Video được tưởng tượng có thể không khớp với domain của agent (khác embodiment, background, physics). Bước Project sử dụng **semantic similarity** để tìm frame thực tế trong dataset gần nhất với mỗi frame tưởng tượng:

$$o_t = \arg \max_{o_t} \frac{\mathcal{E}(o_{t-k:t}) \cdot \mathcal{E}(i_{t-k:t})}{\|\mathcal{E}(o_{t-k:t})\| \|\mathcal{E}(i_{t-k:t})\|} \quad \forall t \in [T] \quad (64)$$

trong đó $\mathcal{E}$ là hàm embedding của SigLIP – một mô hình vision-language được pretrain trên dữ liệu internet-scale. Sử dụng $k = 3$ frame liên tiếp giúp nắm bắt thông tin về vận tốc và gia tốc, cải thiện độ chính xác matching.

Bước 3 – Imitate (Bắt chước):

Đây là bước cốt lõi của RLZero. Cho chuỗi trạng thái projected $\{s_1, s_2, \dots, s_T\}$ như “expert trajectory”, bài toán imitation learning được công thức hóa như khớp phân phối:

$$z_{\text{imit}} = \arg \min_z \mathcal{D}(\rho^{\pi_z}(s), \rho^E(s)) \quad (65)$$

trong đó ρ^E là phân phối trạng thái của expert trajectory và ρ^{π_z} là phân phối trạng thái của chính sách π_z .

Theorem 1 [19] chứng minh rằng với KL divergence, z_{imit} có thể tính được dưới dạng closed-form mà *không cần gradient updates hay tương tác với môi trường*:

$$z_{\text{imit}} = \mathbb{E}_{\rho^E}[\phi(s)] \quad (66)$$

trong đó $\phi(s)$ là backward representation đã học của BFM. Nói cách khác, z_{imit} chỉ đơn giản là **trung bình của các state representations trong expert trajectory** – một phép tính cực kỳ đơn giản và hiệu quả.

Kết quả Thực nghiệm RLZero được đánh giá trên 25 tasks trong 4 môi trường continuous control từ DeepMind Control Suite: Walker, Cheetah, Quadruped, và Stickman. Kết quả (Bảng 7) cho thấy:

Bảng 7: Win rate của các phương pháp khi đánh giá bằng GPT-4o-preview trên 25 tasks trong DeepMind Control Suite.

Phương pháp	Win Rate
Image-language reward (IQL)	51.2%
Video-language reward (TD3)	40.0%
RLZero (của chúng tôi)	83.2%

Nguồn: [19].

RLZero đạt win rate **83.2%** so với baseline tốt nhất (Image-language IQL: 51.2%), đồng thời chỉ cần **khoảng 25 giây** [19] để tạo ra chính sách zero-shot mà không cần bất kỳ gradient update hay tương tác mới nào với môi trường.

Cross-Embodiment Transfer Một khả năng đặc biệt của RLZero là **cross-embodiment transfer**: có thể bỏ qua bước Imagine và trực tiếp dùng video từ YouTube (quay người thật) làm expert trajectory cho robot có hình dạng khác hoàn toàn. Trên 10 video YouTube trong môi trường Stickman (2D Humanoid), RLZero đạt win rate **80%** so với SMODICE – phương pháp imitation learning từ state-only data – điều mà chưa phương pháp nào trước đó làm được [19].

Tóm tắt Bài báo Gốc Bài báo RLZero của Sikchi và cộng sự [19] giải quyết một thách thức cơ bản trong việc triển khai RL vào thực tế: làm thế nào để một agent có thể thực hiện hành vi được chỉ định bằng ngôn ngữ tự nhiên mà không cần bất kỳ dữ liệu có nhãn nào trong domain đó?

Các phương pháp trước đây như GenRL hoặc image-language reward đều yêu cầu một trong hai điều: hoặc dữ liệu demonstration có nhãn liên kết ngôn ngữ với hành vi cụ thể trong domain, hoặc quá trình training tốn nhiều giờ cho mỗi task mới. Điều này làm hạn chế khả năng mở rộng khi số lượng task tăng lên.

RLZero đề xuất framework gồm ba bước tuần tự **Imagine – Project – Imitate**. Theorem 1 chứng minh rằng với KL divergence, bài toán imitation learning từ expert trajectory có nghiệm closed-form $z_{\text{imit}} = \mathbb{E}_{\rho^E}[\phi(s)]$ – không yêu cầu gradient updates hay tương tác với môi trường.

Kết quả thực nghiệm trên 25 tasks trong DeepMind Control Suite cho thấy win rate 83.2% so với baseline tốt nhất (Image-language IQL: 51.2%), với thời gian inference chỉ khoảng 25 giây – không cần training thêm. Với chuyển giao xuyên thể xác từ 10 video YouTube, RLZero đạt 80% win rate trên môi trường Stickman khi bắt chước video người thật.

Bài báo thừa nhận hai hạn chế chính. Thứ nhất, chất lượng pipeline phụ thuộc hoàn toàn vào khả năng của VFM – khi VFM tưởng tượng sai hành vi phức tạp, toàn bộ pipeline thất bại. Thứ hai, bước Project dựa vào cosine similarity của SigLIP có thể bị ảnh hưởng bởi background distractors hoặc rough symmetries của agent, dẫn đến matching sai frame.

3.4. Data Tự Sinh

Trong các phần trước, dữ liệu luôn được coi là cho trước. Phần IV đặt câu hỏi: làm thế nào để agent *tự thu thập* dữ liệu của mình? Đây là một câu hỏi quan trọng mà các generative model thông thường không giải quyết được, nhưng RL lại có bộ công cụ phù hợp.

3.4.1. Bài toán Khám phá

Coverage và Occupancy Measures Cách phổ biến nhất để nghĩ về exploration là theo nghĩa **coverage** – agent cần khám phá càng nhiều trạng thái càng tốt. Sử dụng lens của thước đo chiếm dụng, mục tiêu này có thể được hình thức hóa: thay vì học thước đo chiếm dụng gán xác suất cao cho các quỹ đạo có reward cao (như trong RL thông thường), chúng ta muốn học thước đo chiếm dụng gán xác suất cho **tất cả** các quỹ đạo:

RL thông thường: $\rho^\pi(s)$ tập trung vào vùng reward cao

Exploration: $\rho^\pi(s)$ trải đều khắp không gian trạng thái

Tuy nhiên, exploration không chỉ là đi khắp nơi – mà còn là **chuẩn bị để giải quyết các nhiệm vụ mới trong tương lai**. Câu hỏi đặt ra là: làm thế nào để agent học các kỹ năng có thể tái sử dụng từ quá trình khám phá?

3.4.2. Trao quyền

Định nghĩa và Ý nghĩa Trao quyền [7] là một framework để định lượng “khả năng làm nhiều thứ” của agent tại một trạng thái nhất định. Trao quyền được đo bằng thông tin tương hỗ giữa hành động và trạng thái tương lai:

$$I(a; s' | s) = \mathcal{H}[s' | s] - \mathcal{H}[s' | s, a] = \mathcal{H}[a | s] - \mathcal{H}[a | s, s'] \quad (67)$$

Trong đó $\mathcal{H}[\cdot]$ ký hiệu entropy. Phương trình (67) có thể được hiểu theo hai cách tương đương:

- *Góc nhìn 1*: Mức độ hành động a làm giảm sự không chắc chắn về s' – tức là hành động tác động đến tương lai mạnh đến mức nào.
- *Góc nhìn 2*: Mức độ biết trạng thái đích s' cho phép suy ra hành động đã thực hiện.

Trao quyền cao tương ứng với việc agent đứng ở vị trí có *nhiều lựa chọn*: đứng ở ngã tư có trao quyền cao hơn đứng ở ngõ cụt. Agent học cách tự điều hướng đến các vị trí có trao quyền cao, tích lũy khả năng hành động cho tương lai. Khái niệm này cũng được mở rộng sang setting **multi-agent**: thay vì tự trao quyền bản thân, AI agent có thể học cách trao quyền con người, hỗ trợ con người có nhiều lựa chọn và khả năng hành động hơn.



Hình 14: Trao quyền được đo bằng thông tin tương hỗ giữa hành động và trạng thái tương lai. Vị trí ngã tư có trao quyền cao (nhiều phương án tác động đến tương lai) so với ngõ cụt (trao quyền thấp). Nguồn: [7].

3.4.3. Học Kỹ năng

Mục tiêu Pure exploration hay maximization trao quyền đơn thuần không đủ để trang bị cho agent các kỹ năng cụ thể. Giải pháp là học **skills** – các temporal abstraction có thể tái sử dụng để giải quyết downstream tasks. Đây còn được gọi là **self-supervised reinforcement learning**: agent tự tạo ra reward của mình thông qua intrinsic motivation.

Mục tiêu toán học là tối đa hóa **thông tin tương hỗ** giữa skill label z và quỹ đạo τ :

$$\max_{\pi} I^{\pi}(z; \tau) = \max_{\pi} [\mathcal{H}[\tau] - \mathcal{H}[\tau | z]] \quad (68)$$

Phương trình (68) gồm hai số hạng với ý nghĩa đối lập:

- $\mathcal{H}[\tau]$: entropy biên của quỹ đạo – muốn **tối đa hóa**, tức là tổng thể hành vi phải đa dạng (mỗi skill làm một hành vi khác nhau).
- $\mathcal{H}[\tau | z]$: entropy có điều kiện của quỹ đạo khi biết skill – muốn **tối thiểu hóa**, tức là với mỗi skill z cụ thể, hành vi phải nhất quán và dễ đoán.

Thuật toán Thực tế Để tối đa hóa (68), cần có một classifier $q(z | s)$ đoán skill từ trạng thái. Thuật toán alternates giữa hai bước:

Tối ưu chính sách: với classifier q cố định, bài toán tương đương RL với reward:

$$r_t = \log q(z | s_t) \quad (69)$$


Reward cao khi classifier đoán đúng skill từ trạng thái hiện tại – khuyến khích chính sách làm hành vi rõ ràng, dễ nhận biết.

Tối ưu posterior: với chính sách π cố định, cập nhật $q(z | s)$ bằng maximum likelihood trên dữ liệu (s, z) .

Thuật toán Cụ thể: DIAYN và VISR Framework trên được hiện thực hóa trong hai thuật toán tiêu biểu được đề cập trong tutorial:

DIAYN – Diversity is All You Need [7] là cài đặt trực tiếp của mục tiêu mutual information trên, sử dụng SAC (Soft Actor-Critic) cho bước chính sách optimization và một mạng discriminator đơn giản làm $q(z | s)$. DIAYN huấn luyện hoàn toàn không có reward bên ngoài, chỉ dùng intrinsic reward $r_t = \log q(z | s_t) - \log p(z)$. Kết quả là agent tự học được các kỹ năng đa dạng (chạy, nhảy, cân bằng...) mà không cần bất kỳ reward engineering nào từ người dùng.

VISR – Variational Intrinsic Successor Representations [7] kết hợp học kỹ năng với successor representations: thay vì discriminator phân biệt skill từ trạng thái tức thì s_t , VISR học phân biệt skill từ toàn bộ successor feature – tức là “tất cả các trạng thái mà agent sẽ ghé thăm trong tương lai”. Điều này giúp skill có tính **temporal consistency** rõ ràng hơn và có thể được tái sử dụng trực tiếp trong học tăng cường không cần huấn luyện lại thông qua forward-backward representations.



Hình 15: Minh họa Skill Learning (DIAYN): agent học các skill đa dạng (chạy, nhảy, cân bằng) bằng cách tối đa hóa thông tin tương hỗ giữa skill label z và quỹ đạo τ . Discriminator $q(z|s)$ học nhận biết skill từ trạng thái, tạo ra intrinsic reward cho chính sách. Nguồn: [7].

Giải quyết Downstream Tasks Sau khi học xong tập skills, có nhiều cách sử dụng để giải quyết downstream tasks:

1. **Enumeration**: liệt kê tất cả skills và chọn skill có reward cao nhất.
2. **Posterior inference**: dùng $q(z | \tau)$ để suy ra skill phù hợp từ quỹ đạo mẫu.
3. **Hierarchical RL**: coi skills là high-level actions, xây dựng MDP mới với horizon ngắn hơn.

Góc nhìn Nén (Compression) Một cách nhìn tổng quát về học kỹ năng là qua lăng kính **nén thông tin**:

- Học có giám sát: nén Y cho X (labels cho inputs).
- Học không giám sát (VAE, LLM): nén tập dữ liệu X .
- **Học tăng cường tự giám sát**: nén một **MDP** – không phải dữ liệu có sẵn, mà là toàn bộ không gian hành vi của môi trường.

Sản phẩm của quá trình nén này là một **Behavioral Foundation Model (BFM)** – một chính sách có thể được “prompt” để thực hiện nhiều hành vi khác nhau, tương tự như cách LLM được prompt để thực hiện nhiều tác vụ ngôn ngữ. Điểm khác biệt quan trọng: trong khi LLM được huấn luyện trên dữ liệu curated từ internet, BFM được huấn luyện trên **dữ liệu tự thu thập** – agent tự khám phá môi trường và tự tạo ra dataset của mình.

Phân tích Hạn chế và Đề xuất Cải tiến

Trong quá trình nghiên cứu RLZero và các phương pháp liên quan, nhóm chúng tôi nhận thấy một số hạn chế quan trọng mà bài báo gốc chưa giải quyết triệt để.

Hạn chế 1: “What I Cannot Imagine, I Cannot Imitate”

Video generation model được sử dụng trong RLZero (kiến trúc GRU + MLP ensemble từ GenRL [19]) nhạy cảm với prompt engineering. Khi gặp các hành vi phức tạp (ví dụ: “raise hand while standing in place”), model tưởng tượng sai hoàn toàn (Hình 4a trong [19]). Đây là một **bottleneck cơ bản**: chất lượng của toàn bộ pipeline phụ thuộc hoàn toàn vào khả năng tưởng tượng của video generation model.

Phân tích sâu: Vấn đề này không chỉ đến từ kích thước model mà còn từ **distribution mismatch**: video generation model được huấn luyện trên dữ liệu domain của agent (ví dụ: Stickman animations), nhưng các hành vi phức tạp có thể nằm ngoài phân phối training. Thêm vào đó, model sử dụng kiến trúc GRU đơn giản không đủ khả năng mô hình hóa các hành vi có cấu trúc thời gian dài.

Hướng cải tiến: Sử dụng các video foundation model lớn hơn như Sora hay Stable Video Diffusion, hoặc áp dụng kỹ thuật **retrieval-augmented generation**: thay vì sinh video từ đầu, truy xuất video gần nhất từ một database lớn và dùng làm khởi điểm.

Hạn chế 2: Thất bại trong Semantic Search

Bước Project dựa hoàn toàn vào cosine similarity trong embedding space của SigLIP. Tuy nhiên, có hai trường hợp thất bại hệ thống:

1. **Background distractors**: SigLIP latches vào đặc trưng background (màu sắc, texture) thay vì pose của agent, dẫn đến matching sai.
2. **Rough symmetries**: với các agent gần đối xứng (Walker khi đầu và chân trông gần giống nhau), image retrieval trả về frame bị lật ngược hoặc nhầm chiều.

Phân tích sâu: Đây là hạn chế **cơ bản của representation learning**: SigLIP không được thiết kế đặc biệt cho việc phân biệt pose của agent trong RL environments. Embedding space tối ưu cho image-text matching trên internet data không nhất thiết tối ưu cho body pose matching.

Hướng cải tiến: Có thể fine-tune SigLIP trên dữ liệu domain cụ thể của agent (body pose matching), hoặc sử dụng các representation chuyên biệt hơn như pose estimation model kết hợp với keypoint matching. Một hướng khác là học **domain-adaptive embedding**: trong bước Project, học thêm một hàm mapping từ video

frame về agent observation space thay vì chỉ dùng cosine similarity trong general-purpose embedding space.

4. Thực nghiệm và Kết quả

Để kiểm chứng trực quan cơ chế hoạt động của thuật toán Diffusion-DICE và làm rõ nguyên lý chống chịu lỗi ngoại suy (khai thác lỗi), chúng tôi đã tự cài đặt từ đầu bài toán mô phỏng **2D Bandit Toy Case** bằng Python, lấy cảm hứng và tái hiện kịch bản toy case được trình bày trong bài báo gốc Diffusion-DICE [14] và tutorial ICML 2025 [7]. Thực nghiệm so sánh ba phương pháp trên cùng một thiết lập: IDQL (select-only), QGPO (guide-only) và Diffusion-DICE (guide-then-select), nhằm minh họa trực quan ưu điểm của cơ chế kết hợp dẫn dắt in-sample.

4.1. Thiết lập Bài toán

Bài toán 2D Bandit giả lập không gian hành động liên tục $a \in \mathbb{R}^2$ với tập dữ liệu ngoại tuyến $\mathcal{D}$ gồm 1.500 mẫu phân bố trong vùng hình vành khăn (annular region):

$$1.5 \leq \|a\|_2 \leq 2.5$$

Vùng bên trong ($\|a\|_2 < 1.5$) hoàn toàn không có dữ liệu, đây là vùng Ngoài Phân phối (OOD). Hàm phần thưởng thực tế $R(a)$ đạt cực đại tại hai điểm trên đường tròn ngoài ($\|a\|_2 = 2.5$) ở $\theta = 0$ và $\theta = \pi$:

$$R(a) = \exp\left(-\frac{(\|a\|_2 - 2.5)^2}{0.5}\right) \cdot \frac{\cos(2\theta) + 1}{2}$$

Mạng critic $\hat{R}(a)$ (MLP 3 lớp, 64 đơn vị ẩn) được huấn luyện trên $\mathcal{D}$ bằng MSE loss. Do không có dữ liệu tại tâm, mạng MLP bị lỗi ngoại suy sai lệch và tạo ra đỉnh giá trị cực đại giả (*overestimation peak*) tại tâm $(0, 0)$, giả lập chính xác bẫy giá trị thường gặp trong Offline RL thực tế.

Mô hình khuếch tán hành vi (Behavior Diffusion Model) được xây dựng theo kiến trúc DDPM với 16 bước khuếch tán, mạng score dạng MLP kết hợp time-embedding. Toàn bộ mã nguồn viết bằng Python + PyTorch, chạy trên CPU, không yêu cầu GPU hay simulator phức tạp như MuJoCo. Thời gian chạy khoảng 3–5 phút trên máy tính thông thường.

4.2. Các Phương pháp So sánh

Chúng tôi cài đặt 3 phương pháp trên cùng một mô hình khuếch tán hành vi đã được huấn luyện:

1. **IDQL (Select-only)**: Sinh 500 hành động ứng viên từ mô hình khuếch tán hành vi unguided, sau đó dùng $\hat{R}(a)$ để lựa chọn 64 hành động có giá trị cao nhất.
2. **QGPO (Guide-only)**: Dẫn dắt quá trình khuếch tán ngược bằng đạo hàm của critic:

$$\epsilon_{\text{guided}} = \epsilon_b - \eta \sqrt{1 - \bar{\alpha}_t} \cdot \nabla_{a_t} \hat{R}(a_t)$$

với guidance scale $\eta = 0.5$.

3. **Diffusion-DICE (Guide-then-select)**: Tối ưu biến đổi ngẫu nhiên V của DICE với piecewise f -divergence để tính trọng số in-sample:


$$w^*(a) = (f')^{-1} \left(\frac{\hat{R}(a) - V}{\alpha} \right)$$

Huấn luyện mạng chỉ dẫn $g_\theta(a_t, t)$ với IGL loss:

$$\mathcal{L}_{\text{IGL}} = \mathbb{E}[w^*(a) e^{-g_\theta} + g_\theta]$$

Sinh mẫu có chỉ dẫn từ $\nabla_{a_t} g_\theta$ với $\eta = 1.0$, sau đó lọc chọn 64 hành động tốt nhất từ 500 ứng viên theo $\hat{R}(a)$.

4.3. Kết quả Thực nghiệm



Hình 16: Kết quả trực quan hóa bài toán 2D Bandit Toy Case trên Annular Dataset. Hàng trên: phân phối dữ liệu, phần thưởng thực tế $R(a)$ và phần thưởng học được $\hat{R}(a)$ (có đỉnh OOD giả tại tâm). Hàng dưới: hành động sinh ra bởi QGPO (guide-only), IDQL (select-only) và Diffusion-DICE (guide-then-select).


Phân tích kết quả:

- **QGPO** không bị kéo sập hoàn toàn vào tâm OOD $(0, 0)$ mà phân tán rộng thành một dạng vành khuyên bao quanh tâm. Điều này là do sự thiếu hụt dòng gradient dẫn đường hiệu quả từ critic trong quá trình lấy mẫu (ảnh hưởng từ thiết lập huấn luyện và đánh giá). Tuy nhiên, QGPO thể hiện chất lượng sinh mẫu kém, các hành động bị phân tán rất rộng và không thể hội tụ vào hai vùng phần thưởng cao thực tế trên vành ngoài.
- **IDQL** sinh mẫu tập trung tương đối tốt ở hai vùng phần thưởng cao ($\theta \approx 0$ và $\theta \approx \pi$). Do IDQL chỉ lọc chọn hành động từ các ứng viên được sinh sẵn bởi behavior model (vốn nằm trong support của dữ liệu $\mathcal{D}$), phương pháp này tránh được việc bị kéo sập hoàn toàn vào tâm OOD $(0, 0)$, mặc dù critic bị lỗi ngoại suy overestimation tại đó. Dù vậy, vẫn xuất hiện một số ít điểm bị rò rỉ vào vùng tâm (khoảng 4–5 mẫu) do sự ngẫu nhiên của quá trình sinh ứng viên.

- **Diffusion-DICE** sinh mẫu chính xác và tập trung dày đặc nhất tại hai đỉnh phần thưởng thực tế trên vành ngoài, hoàn toàn tránh được bẫy OOD ở tâm (với tỉ lệ rò rỉ rất nhỏ tương tự IDQL). Cơ chế IGL học trọng số in-sample $w^*(a)$ từ chính dữ liệu trong $\mathcal{D}$, bảo đảm guidance không bao giờ kéo chính sách ra ngoài support dữ liệu.

4.4. Mở rộng 1: Thực nghiệm trên Tập dữ liệu 4 Cụm (4-Cluster)

Để kiểm tra khả năng tổng quát của Diffusion-DICE với phân phối dữ liệu phức tạp và rời rạc hơn, chúng tôi thử nghiệm thêm tập dữ liệu gồm 4 cụm Gaussian độc lập có tâm tại $(\pm 2.2, \pm 2.2)$ với độ lệch chuẩn $\sigma = 0.25$.



Hình 17: Kết quả trực quan hóa trên tập dữ liệu 4 cụm Gaussian rời rạc (4-Cluster Dataset). Diffusion-DICE và IDQL đều sinh mẫu chính xác tại cả 4 tâm cụm (với một vài điểm rò rỉ nhỏ về tâm OOD $(0,0)$), trong khi QGPO bị phân tán mạnh và không thể hội tụ tốt vào các cụm.

Phân tích kết quả:

- Trong kịch bản phân phối rời rạc này, cả **Diffusion-DICE** và **IDQL** đều thể hiện khả năng mô hình hóa đa phương thức (multi-modal) tốt khi tập trung hành động tại tâm của cả 4 cụm Gaussian thật. IDQL (select-only) không bị kéo sập


về gốc $(0,0)$ (nơi critic bị overestimation cực đại) vì các ứng viên được tạo ra bởi behavior model nằm hoàn toàn trong support của dữ liệu thực tế. Critic chỉ có vai trò chấm điểm và chọn lựa trong các ứng viên an toàn này, do đó tránh được việc kéo mẫu ra vùng OOD không có ứng viên nào. Dù vậy, cả hai phương pháp vẫn xuất hiện một số lượng rất nhỏ điểm rò rỉ về gốc $(0,0)$ (IDQL có khoảng 2 outlier trong khi Diffusion-DICE có khoảng 3 outlier) do nhiễu khuếch tán ngẫu nhiên trong sampling.

- **QGPO** là phương pháp thất bại rõ ràng nhất: các điểm đầu ra phân tán rải rác khắp không gian, không hội tụ có nghĩa vào bất kỳ cụm nào, phản ánh hạn chế cố hữu của cơ chế guide-only khi không có bước selection kiểm soát phân phối đầu ra và thiếu dòng gradient dẫn đường hiệu quả.

4.5. Mở rộng 2: Khảo sát Siêu tham số Hệ số Dẫn đường

Chúng tôi thực hiện khảo sát hệ số dẫn đường $\eta \in \{0.0, 0.2, 0.4, 0.6, 0.8, 1.0, 1.2, 1.5, 2.0\}$ trên Annular Dataset để phân tích định lượng ảnh hưởng của η đến hai chỉ số:

1. **Trong Phân phối (ID) Ratio:** Tỷ lệ hành động sinh ra nằm trong vùng an toàn $1.4 \leq \|a\|_2 \leq 2.6$.
2. **Average True Reward:** Phần thưởng thực tế $R(a)$ trung bình của các hành động sinh ra.



Hình 18: Kết quả khảo sát Guidance Scale cho QGPO và Diffusion-DICE. Trái: Tỷ lệ hành động an toàn (ID Ratio). Phải: Phần thưởng thực tế trung bình (True Reward).

Phân tích đồ thị:

- **Tính an toàn (ID Ratio):** ID Ratio của QGPO giảm nhanh xuống 0 khi $\eta \geq 0.5$ – toàn bộ hành động bị kéo ra ngoài phân phối. Ngược lại, Diffusion-DICE duy trì ID Ratio $\approx 95\%$ – 100% ở mọi giá trị η , chứng minh tính an toàn tuyệt đối của IGL.
- **Hiệu năng (True Reward):** True Reward của QGPO sập về 0 khi η tăng do hành động đổ vào tâm OOD. Diffusion-DICE đạt True Reward cực đại tại $\eta \approx 1.0$ và giữ ổn định, cho thấy guidance scale tối ưu trong khoảng $[0.8, 1.2]$.

Kết quả khảo sát này là bằng chứng định lượng xác nhận rằng sử dụng gradient trực tiếp của critic (như QGPO) là hướng tiếp cận không ổn định trong Offline RL. Cơ chế học chỉ dẫn in-sample dựa trên DICE là cần thiết để đồng thời đảm bảo hiệu năng và tính an toàn của chính sách.

4.6. Mô tả Demo

Demo thực nghiệm được tổ chức trong thư mục `demo/` với cấu trúc như sau:

- `demo/toybandit.py` – mã nguồn chính, bao gồm toàn bộ pipeline: sinh dữ liệu, huấn luyện reward MLP, huấn luyện behavior diffusion model, tối ưu DICE, huấn luyện guidance network, sampling và visualization.
- `demo/requirements.txt` – danh sách thư viện cần thiết (`torch`, `numpy`, `matplotlib`).
- `demo/toybandit_results.png` – kết quả kịch bản Annular gốc (3 thuật toán so sánh).
- `demo/toybandit_cluster_results.png` – kết quả mở rộng trên 4-Cluster Dataset.
- `demo/toybandit_tuning.png` – kết quả khảo sát Guidance Scale (ID Ratio và True Reward theo η).

Để chạy lại demo hoàn toàn độc lập:

```
pip install -r demo/requirements.txt
python demo/toybandit.py
```

Không cần GPU hay simulator phức tạp. Toàn bộ mã nguồn sử dụng PyTorch trên CPU; seed cố định (`torch.manual_seed(42)`, `np.random.seed(42)`) đảm bảo kết quả tái tạo được. Hình ảnh kết quả được lưu tại `demo/toybandit_results.png` và tự động sao chép sang thư mục `report/images/` để đảm bảo biên dịch báo cáo luôn nhất quán.

5. Đánh giá và Kết luận

5.1. Đánh giá tổng thể tutorial

5.1.1. Đóng góp Khoa học Chính

Tutorial *Generative AI Meets Reinforcement Learning* của Eysenbach và Zhang [7] trình bày một khung nhìn thống nhất về mối quan hệ hai chiều giữa hai lĩnh vực từng được coi là tương đối độc lập. Đóng góp khoa học có thể được tóm gọn theo ba luận điểm cốt lõi.

Luận điểm 1: Generative models là công cụ mạnh cho RL. Bằng cách thay thế các thành phần truyền thống của RL (mô hình thế giới, chính sách) bằng các mô hình sinh hiện đại như diffusion model, transformer hay flow matching, hiệu năng của thuật toán RL có thể được cải thiện đáng kể mà không cần thiết kế lại toàn bộ kiến trúc thuật toán. Cụ thể, chính sách khuếch tán trong offline RL (ví dụ Diffusion-DICE [14]) cho thấy rằng biểu diễn phân phối đa mode của hành động là yếu tố quan trọng trong các bài toán có không gian hành động phức tạp.

Luận điểm 2: Quá trình tương tác RL là một generative model. Tutorial làm rõ rằng chính sách tương tác với môi trường tạo thành một mô hình sinh của các quan sát tương lai. Xác suất đến được một trạng thái s_f trong tương lai – tức *thước đo chiếm dụng trạng thái chiết khấu* hay *thước đo kế tiếp* – đóng vai trò tương đương với likelihood trong các mô hình sinh truyền thống. Nhận thức này dẫn tới các thuật toán goal-conditioned RL không cần thiết kế reward thủ công, thay vào đó định nghĩa bài toán hoàn toàn qua dữ liệu (trạng thái đích mong muốn).

Luận điểm 3: RL là công cụ để huấn luyện và cải thiện generative models. Quá trình khử nhiễu của diffusion model có thể được mô hình hóa như một MDP nhiều bước, cho phép fine-tune model theo các mục tiêu downstream không biểu diễn được bằng likelihood (DDPO [1]). Mở rộng hơn, học tăng cường tự giám sát cho phép xây dựng các Behavioral Foundation Model khám phá và nén không gian hành vi của môi trường mà không cần dữ liệu curated hay reward thủ công.

5.1.2. Tính nhất quán và mạch lạc của Khung nghiên cứu

Điểm đáng chú ý là tutorial xây dựng được một luận điểm nhất quán từ đầu đến cuối. Bắt đầu từ quan sát đơn giản rằng hàm điểm số – đối tượng trung tâm của generative modeling – xuất hiện trực tiếp trong gradient chính sách của RL, tutorial dần mở rộng mối liên hệ này qua nhiều lớp: từ reward-weighted regression, đến dual RL, đến thước đo kế tiếp, rồi đến temporal contrastive learning và cuối cùng là học

tăng cường không cần huấn luyện lại. Mỗi bước đều có nền tảng toán học rõ ràng và kết nối trực tiếp với bước tiếp theo.

Cách trình bày này giúp người đọc không chỉ nắm bắt từng phương pháp cụ thể mà còn hiểu được *tại sao* các kết nối đó tồn tại ở mức nguyên lý, từ đó có thể tự suy ra các biến thể và mở rộng.

5.2. Ưu điểm của Hướng tiếp cận

5.2.1. Loại bỏ sự phụ thuộc vào Thiết kế Hàm Thưởng

Một trong những nút thắt lớn nhất khi triển khai RL trong thực tế là việc thiết kế hàm reward. Reward phải vừa phản ánh đúng mục tiêu của người dùng, vừa đủ dense để tạo gradient học, vừa không bị mô hình khai thác theo cách không mong muốn. Trong nhiều ứng dụng thực tế – robot dọn phòng, phẫu thuật robot, tổng hợp hóa học – việc mã hóa “mục tiêu” thành scalar reward là gần như bất khả thi.

Khung goal-conditioned RL được trình bày trong tutorial giải quyết vấn đề này một cách triệt để. Bằng cách định nghĩa bài toán qua *dữ liệu* (quan sát mục tiêu g) thay vì scalar, người dùng chỉ cần cung cấp ví dụ về trạng thái mong muốn. Phần còn lại – bao gồm đánh giá chính sách và tối ưu – được dẫn xuất tự động từ cấu trúc xác suất. Điều này về cơ bản đưa RL đến gần hơn với phương pháp luận học máy tiêu chuẩn: bài toán được định nghĩa qua dữ liệu, không phải qua code đặc thù.

5.2.2. Mở rộng Năng lực Biểu diễn của Chính sách

Việc sử dụng diffusion model hay transformer làm chính sách mang lại khả năng biểu diễn phân phối hành động đa mode – điều mà Gaussian chính sách truyền thống không làm được. Trong các bài toán robot manipulation hay tổng hợp hóa học, thường tồn tại nhiều chuỗi hành động hợp lệ để đạt cùng một mục tiêu. Chính sách Gaussian sẽ trung bình hóa các mode này, dẫn tới các hành động không hợp lệ. Chính sách khuếch tán tránh được vấn đề này bằng cách biểu diễn trực tiếp phân phối đa mode.

5.2.3. Khả năng Học Không Giám sát và Dữ liệu Tự thu thập

Góc nhìn học tăng cường tự giám sát (Phần IV của tutorial) giải quyết câu hỏi cơ bản: dữ liệu từ đâu mà có? Thay vì phụ thuộc vào dataset curated do con người tạo ra, agent có thể tự khám phá môi trường, thu thập dữ liệu và tổ chức kiến thức thông qua skill learning. Khung Behavioral Foundation Model [7] cho thấy rằng quá trình học như vậy có thể tạo ra các biểu diễn kỹ năng có khả năng tổng quát hóa mạnh, sẵn

sàng được *prompt* để giải quyết downstream task mới – tương tự LLM nhưng trong không gian hành vi thay vì không gian ngôn ngữ.

5.3. Hạn chế và Thách thức Còn tồn tại

5.3.1. Hạn chế về Khả năng Mở rộng

Mặc dù có nền tảng lý thuyết vững chắc, phần lớn các phương pháp được trình bày trong tutorial vẫn được thực nghiệm trên các môi trường quy mô nhỏ hoặc trung bình (MuJoCo, Atari, maze navigation). Khi chuyển sang các bài toán thực tế với không gian trạng thái và hành động cực kỳ lớn – ví dụ robot thao tác trong môi trường chưa biết, hay điều khiển lò phản ứng hạt nhân – các thuật toán hiện tại vẫn đối mặt với thách thức về hiệu quả mẫu và độ ổn định huấn luyện.

Temporal contrastive learning và estimation thước đo kế tiếp đòi hỏi lượng dữ liệu lớn để ước lượng chính xác trong không gian chiều cao. Mặc dù các biểu diễn log-linear (Section 4.6 của tutorial) có một số tính chất lý thuyết tốt, tính thực tiễn ở quy mô lớn vẫn cần được kiểm chứng thêm.

5.3.2. Vấn đề Dịch chuyển Phân phối

Phần lớn các phương pháp offline RL trong tutorial đều đối mặt với vấn đề distribution shift: chính sách được học từ dữ liệu của behavior policy, nhưng sau đó được triển khai theo phân phối khác. Diffusion-DICE giải quyết phần nào vấn đề này thông qua guide-then-select, nhưng vẫn phụ thuộc vào giả định rằng dataset offline đủ phong phú để phủ được vùng hành động tối ưu.

Trong setting online hay hybrid, vấn đề trở nên phức tạp hơn khi chính sách liên tục cập nhật và phân phối dữ liệu thay đổi theo. Các thuật toán dual RL (Section 3.4) cung cấp công cụ lý thuyết để phân tích vấn đề này, nhưng cài đặt thực tế vẫn yêu cầu nhiều kỹ thuật ổn định hóa bổ sung.

5.3.3. Phụ thuộc vào Chất lượng Mô hình Phần thưởng

Đối với các phương pháp kết hợp reward trong RL fine-tuning generative models (ví dụ DDPO), chất lượng toàn bộ hệ thống phụ thuộc trực tiếp vào độ chính xác của reward model. Khi reward model chỉ là một proxy hẹp cho mục tiêu thực sự của người dùng, mô hình có thể tối ưu proxy thay vì cải thiện chất lượng thực – hiện tượng *reward hacking*. Đây là vấn đề không chỉ của DDPO mà của toàn bộ paradigm RLHF (Reinforcement Learning from Human Feedback) và đang là chủ đề nghiên cứu tích

cực trong cộng đồng.

5.3.4. Thách thức trong Tổng quát hóa

Tutorial kết thúc bằng lời kêu gọi về vai trò của generalization trong RL (Section 6 của tutorial). Đây là một thiếu hụt hiện tại quan trọng: trong khi các mô hình ngôn ngữ và hình ảnh có thể generalize tốt sang các input chưa gặp trong training, hầu hết các RL agent vẫn bị overfitting vào môi trường và phân phối task cụ thể đã train. Học kỹ năng và thước đo kế tiếp cung cấp một số công cụ để giải quyết vấn đề này, nhưng khả năng generalize của RL agent vẫn còn kém xa so với LLM hay visual generative models.

5.4. Hướng Nghiên cứu Tương lai

5.4.1. Tích hợp Mô hình Nền tảng với Học Tăng cường

Một hướng nghiên cứu hứa hẹn là tận dụng các foundation model (LLM, vision-language model) như nguồn prior kiến thức để khởi động quá trình học RL. Trong khi tutorial giới thiệu RLZero như một bước đầu tiên – dùng video generative model để tưởng tượng hành vi mục tiêu – vẫn còn nhiều câu hỏi mở về cách kết hợp language grounding, visual perception và decision-making trong một framework thống nhất.

Đặc biệt, khả năng suy luận theo ngữ cảnh dài của LLM có thể bổ sung hiệu quả cho thước đo kế tiếp trong việc lập kế hoạch nhiều bước. Thay vì chỉ ước lượng xác suất đến trạng thái s_f theo phân phối hình học, có thể kết hợp với khả năng lập kế hoạch ngôn ngữ để xử lý các task phức tạp hơn.

5.4.2. Cải thiện Hiệu quả Mẫu trong Môi trường Thực

Đối với các ứng dụng thực tế như robotics hay y tế, số lượng tương tác với môi trường bị giới hạn nghiêm ngặt. Các phương pháp model-based RL (Section 2.2) kết hợp với mô hình thế giới chất lượng cao (ví dụ diffusion-based mô hình thế giới) là hướng đi tự nhiên để giảm yêu cầu dữ liệu thực. Tuy nhiên, như tutorial đề cập, compounding error của mô hình thế giới vẫn là thách thức lớn cần các kỹ thuật phát hiện và điều chỉnh hiệu quả hơn.

5.4.3. Học Tăng cường Không cần Phần thưởng ở Quy mô Lớn

Học kỹ năng và học tăng cường tự giám sát (Phần IV) đặt nền móng cho RL không cần reward. Bước tiếp theo là đưa paradigm này lên quy mô lớn hơn, tương

đương với scale của LLM pretraining. Câu hỏi mở bao gồm: làm thế nào thiết kế không gian skill $\mathcal{Z}$ sao cho đủ phong phú để biểu diễn đa dạng hành vi? Làm thế nào kết hợp skill learning với instruction following để tạo ra các agent thực sự có thể nhận lệnh ngôn ngữ?

5.4.4. Lý thuyết về Tổng quát hóa trong Học Tăng cường

Như tutorial nhấn mạnh, generalization là *the next frontier* của RL. Cần xây dựng lý thuyết rõ ràng về khi nào và tại sao các biểu diễn học từ một tập task có thể transfer sang task mới. Kết quả về *tổng quát hóa chân trời* [7] – train trên task ngắn, giải được task dài – là một tín hiệu tích cực, nhưng vẫn còn hạn chế ở các setting đặc thù. Việc mở rộng các kết quả này sang không gian trạng thái và hành động liên tục, đa chiều là một bài toán lý thuyết quan trọng.

5.5. Nhận xét về Ý nghĩa Thực tiễn

Nhìn từ góc độ ứng dụng, framework được trình bày trong tutorial có ý nghĩa thực tiễn rõ ràng trong ít nhất ba lĩnh vực.

Đối với **robotics**, khả năng học đạt đích từ video demonstration mà không cần reward (GCBC, goal-conditioned RL) và khả năng biểu diễn chính sách đa mode (chính sách khuếch tán) trực tiếp giải quyết hai điểm yếu lớn nhất của robot learning hiện tại: thiếu dữ liệu có nhãn reward và sự đa dạng của chuỗi hành động hợp lệ.

Đối với **LLM agents**, việc nhìn nhận chuỗi token generation như một MDP (tương tự DDPO áp dụng cho diffusion model) cung cấp nền tảng lý thuyết cho RLHF và các phương pháp fine-tuning bằng reward. Framework dual RL và thước đo kế tiếp còn gợi ý các cách mới để đánh giá và tối ưu khả năng lập kế hoạch của LLM mà không phụ thuộc vào human annotation.

Đối với **khoa học và kỹ thuật** (điều khiển lò phản ứng, thiết kế phân tử, tối ưu hóa quy trình công nghiệp), việc kết hợp mô hình thể giới chất lượng cao với thuật toán RL hiệu quả mẫu mở ra khả năng học chính sách tốt với rất ít tương tác thực với hệ thống vật lý – giảm thiểu chi phí và rủi ro trong quá trình thực nghiệm.

5.6. Kết luận

Tutorial *Generative AI Meets Reinforcement Learning* của Eysenbach và Zhang tại ICML 2025 trình bày một quan điểm thống nhất và có chiều sâu về mối quan hệ giữa hai lĩnh vực. Từ reward-weighted regression, chính sách khuếch tán, Diffusion-DICE

đến temporal contrastive learning, dual RL, skill learning và học tăng cường không cần huấn luyện lại, mỗi chủ đề đều được gắn kết bởi một ngôn ngữ toán học chung: phân phối xác suất trên quỹ đạo, hàm điểm số, và thước đo kế tiếp.

Báo cáo này đã tổng hợp và trình bày các nội dung chính của tutorial qua bốn phần: kiến thức nền về RL và generative models (Phần 2), ứng dụng generative models trong RL bao gồm mô hình thế giới, chính sách khuếch tán và DDPO (Phần 3), tương tác như generative model – goal-conditioned RL, dual RL, thước đo kế tiếp và skill learning (Phần 4), cùng với kết quả thực nghiệm minh họa (Phần 5).

Nhóm nhận thấy rằng đóng góp lớn nhất của tutorial không chỉ nằm ở các thuật toán cụ thể, mà ở chỗ nó cung cấp một *khung nhìn* giúp các nhà nghiên cứu từ cả hai phía – generative modeling và RL – có thể đọc hiểu kết quả của nhau và phát triển ý tưởng mới ở giao thoa. Khi mô hình ngôn ngữ lớn và các hệ thống agent ngày càng phát triển, sự hợp nhất giữa generative AI và reinforcement learning không còn là một hướng nghiên cứu tùy chọn mà đang trở thành nền tảng không thể thiếu.

Bảng 8: Tóm tắt các phương pháp chính và vị trí trong framework

Phương pháp	Vai trò	Đóng góp chính
Reward-weighted Regression	Dữ liệu trong RL	Kết nối RL và maximum likelihood
Diffusion Policy / Diffusion-DICE	Chính sách biểu diễn phong phú	Xử lý phân phối đa mode trong offline RL
DDPO	Fine-tune generative model	RL objective cho diffusion model
Goal-conditioned RL / GCBC	Loại bỏ reward engineering	Định nghĩa bài toán qua dữ liệu
Temporal Contrastive Learning	Ước lượng thước đo kế tiếp	Học biểu diễn không cần reward
Dual RL / DICE	Phân tích phân phối dữ liệu	Thống nhất on-policy và off-policy
Skill Learning / BFM	Khám phá và tổ quát hóa	Agent tự tạo dữ liệu và kỹ năng
RLZero	Suy luận task không cần huấn luyện lại	Điều khiển từ ngôn ngữ, không cần giám sát

Tài liệu

- [1] Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, and Sergey Levine. Training diffusion models with reinforcement learning. In *International Conference on Learning Representations*, 2024.
- [2] Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, and Sergey Levine. Training diffusion models with reinforcement learning: Project page, 2024.
- [3] Lili Chen, Kevin Lu, Aravind Rajeswaran, Kimin Lee, Aditya Grover, Michael Laskin, Pieter Abbeel, Aravind Srinivas, and Igor Mordatch. Decision transformer: Reinforcement learning via sequence modeling. In *Advances in Neural Information Processing Systems*, 2021.
- [4] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2025.
- [5] Kurtland Chua, Roberto Calandra, Rowan McAllister, and Sergey Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. In *Advances in Neural Information Processing Systems*, 2018.
- [6] Marc Deisenroth and Carl E. Rasmussen. PILCO: A model-based and data-efficient approach to policy search. In *Proceedings of the 28th International Conference on Machine Learning*, pages 465–472, 2011.
- [7] Benjamin Eysenbach and Amy Zhang. Notes from an ICML 2025 tutorial: Generative AI meets reinforcement learning, 2025. ICML 2025 tutorial notes.
- [8] Jesse Farebrother, Matteo Pirodda, Andrea Tirinzoni, Rémi Munos, Alessandro Lazaric, and Ahmed Touati. Temporal difference flows, 2025. arXiv preprint.
- [9] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. *arXiv preprint arXiv:1912.01603*, 2019.
- [10] Philippe Hansen-Estruch, Ilya Kostrikov, Michael Janner, Jakub Grudzien Kuba, and Sergey Levine. IDQL: Implicit q-learning as an actor-critic method with diffusion policies. *arXiv preprint arXiv:2304.10573*, 2023.
- [11] Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, 2022.

-
- [12] Michael Janner, Qiyang Li, and Sergey Levine. Offline reinforcement learning as one big sequence modeling problem. In *Advances in Neural Information Processing Systems*, 2021.
 - [13] Cheng Lu, Huayu Chen, Jianfei Chen, Hang Su, Chongxuan Li, and Jun Zhu. Contrastive energy prediction for exact energy-guided diffusion sampling in offline reinforcement learning. In *International Conference on Machine Learning*, pages 22825–22855, 2023.
 - [14] Liyuan Mao, Haoran Xu, Xianyuan Zhan, Weinan Zhang, and Amy Zhang. Diffusion-DICE: In-sample diffusion guidance for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, 2024.
 - [15] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, 2022.
 - [16] Keiran Paster, Sheila A. McIlraith, and Jimmy Ba. You can’t count on luck: Why decision transformers and RvS fail in stochastic environments. In *Advances in Neural Information Processing Systems*, 2022.
 - [17] Jan Peters and Stefan Schaal. Reinforcement learning by reward-weighted regression for operational space control. In *Proceedings of the 24th International Conference on Machine Learning*, pages 745–750, 2007.
 - [18] Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. Ai models collapse when trained on recursively generated data. *Nature*, 2024.
 - [19] Harshit Sikchi, Siddhant Agarwal, Pranaya Jajoo, Samyak Parajuli, Caleb Chuck, Max Rudolph, Peter Stone, Amy Zhang, and Scott Niekum. RL zero: Zero-shot language to behaviors without any supervision. *arXiv preprint arXiv:2412.05718*, 2024.
 - [20] Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8:229–256, 1992.